

Estrategia de un lago de datos para flujos de trabajo en ciencia de datos

Data Lake Strategy for Data Science Workflows

Dirección del Laboratorio de Ciencia de Datos y Métodos
Modernos de Producción de Información, Instituto Nacional
de Estadística y Geografía (INEGI)
Av. Héroe de Nacozari no 2301, Aguascalientes, México
lcid@inegi.org.mx

VILLASEÑOR GARCÍA, ELIO ATENÓGENES elio.villaseñor@inegi.org.mx
CORONADO IRUEGAS, ABEL ALEJANDRO abel.coronado@inegi.org.mx
PIMENTEL ALARCÓN, ALEJANDRO ESTEBAN
alejandro.pimentel@inegi.org.mx
SUÁREZ PONCE DE LEÓN, RANYART RODRIGO ranyart.suarez@inegi.org.mx
FIGUEROA MARTÍNEZ, ALEJANDRA alejandra.figueroa@inegi.org.mx
ESQUER MARTÍNEZ, AMADO amado.esquer@inegi.org.mx
SILVA CUEVAS, VÍCTOR victor.silva@inegi.org.mx
CABRERA ZAMORA, IRVING GIBRÁN irving.cabrera@inegi.org.mx
DÍAZ, EDGAR OSWALDO oswaldo.diaz@inegi.org.mx

Resumen — El presente documento detalla la investigación y estrategia tecnológica realizadas para implementar un Lago de Datos y Areneros del Laboratorio de Ciencia de Datos, en el Instituto Nacional de Estadística y Geografía (INEGI) de México. Este proyecto busca integrar información digital, estadística y geográfica, de varios repositorios, así como fuentes de datos internas y externas, generados por diversos entes de información, en diversos formatos, para conjuntarlos en un ambiente unificado de almacenamiento (temporal o permanente), que permita llevar a cabo procesos avanzados con técnicas orientadas al análisis y a la ciencia de datos.

Palabras Clave – Lago de datos, areneros, ciencia de datos.

Abstract — This paper details the research and technological strategy carried out to implement a Data Lake and Sandboxes of the Data Science Laboratory at the National Institute of Statistics and Geography (INEGI) Mexico. This project seeks to integrate digital information from different repositories, data sources internal and external, which exist by the various entities that generate statistical and geographic information, in various formats to combine them in a unified storage environment (temporary or permanent), which allows advanced processes to be carried out with techniques oriented towards analytics and data science.

Keywords – data lake, sandbox, data science.

I. INTRODUCCIÓN

La estrategia se basa en implementar un entorno flexible, que permita incorporar componentes basados en herramientas de hardware y software. Se tiene como objetivo generar un lago de datos para que grandes volúmenes de información digital, estadística y geográfica, en diversos formatos, recolectada, almacenada y procesada en un ambiente con acceso controlado para su integridad, disponibilidad y confidencialidad, así como automatizar procesos ágiles, basados en flujos de integración y despliegue continuo, para realizar modelos de información (datos, metadatos, microdatos), que sirvan como insumo para la analítica y ciencia de datos.

II. ESTADO DEL ARTE

Un lago de datos es un área de almacenamiento compartido de grandes volúmenes de datos, de tipo estructurado y no estructurado, con diferentes formatos de solo lectura, para la interacción de sus componentes (hardware y software), lo que

permite generar estrategias para la creación de conocimiento a partir de minería, análisis y ciencia de datos recopilados. De esta manera se avanza en el descubrimiento y explotación de información ad hoc, en tiempo real, para generar visualizaciones cuantitativas o cualitativas que apoyen la toma de decisiones.

Un arenero o Sandbox es un entorno controlado, con base en tecnologías de información, escalable, para ejecutar herramientas especializadas con niveles de seguridad y de manera independiente, permitiendo controlar los recursos de hardware y software que son utilizados en el acceso al lago de datos. Tiene la finalidad de apoyar en la generación de productos prototipos, orientados en analítica y ciencia de datos.

Algunos casos de éxito muestran la implantación de lagos de datos en oficinas de estadística. En el trabajo desarrollado por Llave (2018) [5], se presenta un panorama general de la implementación de esta estrategia. En el presente estudio se exploran las tecnologías involucradas, así como los beneficios directos e indirectos. Se llega a la conclusión importante que los lagos de datos no reemplazan a los almacenes de datos (Data Warehouses), sino que aumentan las capacidades para el uso de grandes volúmenes de datos.

Anejionu et al. (2019) [1] presentan el SUDS o Sistema de Datos Urbano Espacial, que se emplea en Reino Unido para realizar analítica de datos sociales y económicos en conjunción con un sistema geográfico. Presenta, de manera simplificada, el flujo de la información en un lago de datos. Además, expone una serie de casos de éxito a raíz de la implementación del modelo referido.

Por otra parte, Sfaxi y Ben Aissa (2020) [7] presentan una propuesta de gestión de datos a gran escala, para la toma de decisiones. En el contexto particular del piloto prototipo, plantea un modelo de cuatro fases: en la primera se presenta un lago de datos crudos; es decir, los datos en su estado natural; posteriormente se cuenta con un lago de datos refinados, los cuales sirven a una tercera capa, en la cual se crean vistas de la información a partir de los datos mencionados anteriormente; en la cuarta capa persisten los resultados de la fase de análisis, accesible a través de herramientas de visualización. En cuanto a la aplicación del lago de datos en una oficina de estadística, la Centraal Bureau voor de Statistiek (CBS), Statistics Netherlands (Países Bajos) ha implementado un lago de datos en la institución, capaz de captar los datos de entrada provenientes de

diversas fuentes, conjuntarlos con otros datos generados en la CBS y producir una serie de salidas dirigidas a diversos actores, que pudieran producirse gracias al poder del análisis que se tiene al conjuntar las fuentes en un repositorio común.

III. FASES ESTRATÉGICAS

En la Dirección del Laboratorio de Ciencia de Datos y Métodos Modernos de Producción de Información, adscrito a la Dirección Adjunta de Investigación del INEGI, se ha adoptado una metodología de trabajo ágil, basadas en ocho fases que se describen a continuación:

Fase fuentes de datos: consiste en la selección de las fuentes de información que serán de relevancia para el proyecto de ciencia de datos en cuestión. El responsable de seleccionar las fuentes de información desempeñará el rol de Arquitecto de Big Data. En caso de que el proyecto se desarrolle por una solicitud externa, el solicitante dará acceso a esta información cuando no sea de acceso abierto. Estas fuentes pueden incluir datos, metadatos, microdatos de censos, encuestas, imágenes satelitales geoespaciales, entre otras.

Fase extracción y carga de datos: consiste en la recolección de los datos insumo almacenados en el lago de datos, para implementar las técnicas en ciencia de datos con base en el requerimiento inicial del proyecto. El rol de responsable en esta fase lo tendrá el Ingeniero de Datos, por la implementación de métodos para la extracción y carga de datos, de forma automática o manual; también proporciona el acceso a repositorios internos y/o externos, donde están almacenados los datos, realiza la carga de datos extraídos a la infraestructura del lago de datos y aplica las transformaciones de datos que sean requeridas.

Fase recuperación de información: consiste en implementar estrategias de búsqueda en los conjuntos de datos, metadatos, microdatos, extraídos y cargados en el lago de datos. Las estrategias de búsqueda se pueden implementar con base en estructuras identificadas y descritas por medio de diccionarios de datos con técnicas, que permiten generar grupos de información llamados “conjunto de datos”. Esta etapa podrá llevarse a cabo en distintos momentos del proyecto, de acuerdo con las necesidades que se presenten. El rol de responsable también corresponde al Ingeniero de Datos.

Fase procesamiento de datos: consiste en la implementación y aplicación de técnicas estadísticas e informáticas, en la cual se busca analizar los datos recolectados en las fases anteriores, para tener un mayor entendimiento de la información, así como descubrir aspectos relevantes de los datos, como las relaciones existentes entre las variables que se están analizando, el rol de responsable en esta fase será del Científico de Datos Jr., considerando el análisis exploratorio de datos, con base en las características del requerimiento, la limpieza de datos, el control de calidad de la información relacionada con el proyecto, y la representación de datos que responda a las necesidades de la fase de construcción del modelo.

Fase construcción del modelo: consiste en realizar la selección de los modelos de aprendizaje computacional o modelos estadísticos, según sea el caso, y su implementación en un ambiente controlado. A lo largo del proyecto se podrá

experimentar con distintos modelos. El rol de responsable es del Científico de Datos Sr.

Fase evaluación y validación de resultados obtenidos (del procesamiento y análisis de los datos): se realiza con base en las métricas de desempeño establecidas, así como en el desarrollo de procedimientos estadísticos basados en mejores prácticas internacionales. Se podrá realizar durante distintos momentos a lo largo de la ejecución del proyecto, a fin de contar con criterios para seleccionar el modelo con el mejor desempeño. El rol de responsable en esta fase será del Científico de Datos Sr.

Fase presentación de resultados: consiste en realizar componentes, por medio de herramientas especializadas basadas en tecnologías de información, que permiten mostrar los avances del proyecto en ciencia de datos. El rol de responsable en esta fase será del Científico de Datos Líder, quien podrá considerar para la presentación de resultados la demostración de prototipos de productos de datos en el lago de datos y el arenero, también genera un reporte técnico en que se indica la metodología y el nivel de madurez, construye tableros de control o desarrolla otras estrategias de visualización de datos, y puede elaborar artículos de investigación científica.

Fase entrega de productos de datos: aquí se desarrolla un proceso de implementación en la arquitectura, con base en tecnologías de información, que el solicitante dispone acompañado de su documentación. Además, como parte del proceso de entrega, se podrá incluir una asesoría para el uso del prototipo y la estrategia para reducir riesgos en la operación, basados en el ciclo de vida del proyecto.

Para el cumplimiento de las anteriores fases es necesaria la participación de responsables que desempeñen los siguientes roles:

- Científico de datos líder: responsable de supervisar el desarrollo de los proyectos, así como dirigir la investigación científica, decidir los métodos y procedimientos de ciencia de datos, establecer la estrategia de colaboración, dimensionar las necesidades de infraestructura y promover del desarrollo de nuevas capacidades.
- Científico de datos Sr.: responsable de dirigir la implementación de los métodos y procedimientos de ciencia de datos, y establecer las métricas de desempeño que se requerirán para la evaluación y validación de resultados.
- Científico de datos Jr.: responsable de implementar métodos y procedimientos, así como el desarrollo de artefactos (tableros de control, mapas históricos, visualizaciones, reportes) para la presentación de resultados.
- Arquitecto de flujo de trabajo: responsable de la especificación del flujo de trabajo en los proyectos de ciencia de datos, así como de su registro documental.
- Arquitecto de infraestructura: responsable de la configuración y administración de la infraestructura asignada al Laboratorio de Ciencia de Datos (LCiD).
- Arquitecto de big data: responsable de determinar la estrategia y plataforma tecnológica para la recolección, almacenamiento y procesamiento de grandes volúmenes de

datos, requeridos para cumplir los objetivos particulares de los proyectos de ciencia de datos;

- Ingeniero de datos: responsable de llevar a cabo las tareas de extracción, carga y transformación de datos, así como implementar estrategias de recuperación de información que requieran los proyectos de ciencia de datos.

IV. ESTRATEGIA DE IMPLEMENTACIÓN

Para la implementación del lago de datos y el arenero son utilizadas herramientas tecnológicas (basadas en software con licenciamiento libre, u Open Source), que permiten llevar a cabo las fases descritas, considerando las capas que a continuación se mencionan:

Capa de Interoperabilidad: en esta capa están las herramientas transversales que permiten la integración continua, el control de cambios, y otros aspectos de la caracterización de los proyectos basados en Ingeniería de Software para equipos de trabajo DevSecOps (Developer Security Operation) [3], así como equipos de trabajo para proyectos en Ciencia de Datos DataSecOps (Data Security Operation) [3], el acceso al lago de datos y areneros es restringido mediante el establecimiento de niveles de seguridad.

Las herramientas utilizadas en esta capa son:

- GitLab: una plataforma web de desarrollo de software, que permite gestionar código fuente, la planeación de proyectos y la gestión de flujos automatizados de integración continua. [8]

- MLflow: herramienta para la gestión de proyectos de machine learning, con la cual se pueden registrar, empaquetar, distribuir y consultar experimentos, para obtener modelos reproducibles y robustos. [9]

- Kedro: es un marco para la creación de flujos de datos. Adopta las mejores prácticas en ingeniería de software para crear el código de ciencia de datos que sea reproducible, mantenible y modular. [10]

Capa de ingestión de datos: es la encargada de consumir y hacer acopio de cualquier tipo de fuentes de datos estructurados y no estructurados, interno y externos al INEGI. En este nivel son definidos los microservicios – contenedores que serán implementados en el arenero, pueden ser controladores o conectores, entre otras herramientas o librerías de recolección de información digital.

Las herramientas utilizadas en esta capa son:

- Python: Es un lenguaje de programación de código abierto orientado a objetos. Su sintaxis sencilla y la cantidad de sus librerías facilitan la creación rápida de programas y flujos de información.[11]

- Jupyter Lab – Notebook: Es un entorno de desarrollo web interactivo, con soporte para distintos lenguajes, en los que destaca Python. Permite combinar la ejecución del código con documentación y visualizaciones en un solo archivo, facilitando así la creación de prototipos y la difusión de resultados.[12]

Capa de almacenamiento de datos: se encarga del almacenaje de datos, define los servicios y/o microservicios en contenedores generados para el Arenero. Esto permite, mediante protocolos de

transferencia de datos, el envío de información digital, con el soporte de varios formatos con datos estructurados y no estructurados.

La herramienta utilizada en esta capa es, Minio: un software para servidores de almacenamiento distribuidos bajo el protocolo llamado “S3”, que permite crear nubes privadas de datos de alto desempeño. También realiza interacción estandarizada con otros servicios, para acceder a sus archivos en cualquier formato. [13]

Capa de virtualización de datos: la virtualización de datos generada en el arenero, con herramientas que permiten hacer consultas de la información digital almacenada en el lago de datos, para establecer una estrategia en la generación de tablas de datos de solo lectura sin que haya pérdidas de linaje, con la finalidad de estandarizar los nombres de campos y permitir la disposición de un grupo de datos homogéneo.

Las herramientas utilizadas en esta capa son:

- Trino: Motor de consultas SQL distribuido que permite conectarse a otras fuentes de datos, como servidores que tienen gestores de bases de datos. De esta manera permite la interacción entre ellos dentro de una única interfaz transparente y estandarizada.[14]

- Hive: Este software permite leer, escribir y gestionar conjuntos de datos en almacenamientos distribuidos, utilizando el lenguaje llamado SQL. Permite determinar la estructura de archivos ya existentes, con lo cual es posible hacer consultas de información.[15]

Capa de integración de datos: los servicios o microservicios en contenedores generados en el arenero permiten integrar tecnologías de gestión de información de diversos proveedores (gestores de datos), con lo que se facilita la administración de la información digital almacenada (real o virtual) en el lago de datos, en apoyo al gobierno y la documentación. Entre otras herramientas, se utilizan librerías especializadas, basadas en Python, [16] que permiten el agrupamiento de información para generar un grupo de datos.

Capa de analítica y ciencia de datos: la analítica de datos permite llevar a cabo estudios complejos sobre los datos, empleando algoritmos emanados de un proceso de ciencia de datos. En el arenero, permiten utilizar la información almacenada en el lago de datos, emplean como insumo grupo de datos para el entrenamiento de modelos (aprendizaje automatizado, procesamiento de lenguaje natural, aprendizaje profundo). Los resultados que generan las iteraciones también son almacenados en el lago de datos, en cuanto a su referencia, el grupo de trabajo establecido por proyecto genera prototipos para revisión de niveles de madurez, así como la herramienta utilizada en entornos de trabajo (frameworks) y librerías especializadas basados en Python, [16] que permiten el procesamiento con técnicas de aprendizaje supervisado, no supervisado, profundo y de lenguaje natural, para generar algoritmos que respondan al requerimiento.

Capa de visualización de datos: es el medio mediante el cual, con herramientas especializadas, se pueden generar reportes, graficas o tableros de control que permitan mostrar los indicadores cuantitativos y cualitativos para tomar la decisión

sobre el nivel de madurez del proyecto con ciencia de datos, para luego realizar la entrega del prototipo.

Las herramientas utilizadas en esta capa son:

- SuperSet: es una plataforma de exploración y visualización de datos que puede conectarse a cualquier fuente de datos basada en SQL a través del componente llamado SQLAlchemy, soportando grandes volúmenes de información, con base en escala de petabytes. Cuenta con diversos gráficos y mapas, que se eligen en función de las necesidades. Se configura mediante selectores que son presentados en un tablero de control, basado en tecnología web, permitiendo así el acceso controlado de los usuarios. [17]

- D3.js (Data-Driven Documents): es una librería de JavaScript para manipular documentos basados en datos especializado en visualización con tecnologías web.[18]




Figura 1. Diagrama de fases, capas y herramientas estratégicas utilizadas en la arquitectura del lago de datos y areneros.

Nota: la infraestructura requerida para la implementación de un lago de datos y arenero depende de las características de los proyectos y servicios que se generan. El siguiente es un ejemplo del dimensionamiento básico: generar cuatro servidores físicos o lógicos, que cada servidor tiene 20 núcleos y 40 procesadores lógicos, 256 Gb en memoria RAM, 400 Gb en almacenamiento tipo SSD, y 4 Tb en almacenamiento de tipo SATA. El sistema operativo multiusuario se configura con base en el kernel de Linux, para que soporte las herramientas anteriores mencionadas, con tecnología que permita la contenerización o tecnología de hipervisores. Los métodos de conexión entre los servidores deberán considerar el uso de tecnologías de red de área de almacenamiento SAN (Storage Area Network) y/o almacenamiento conectado en red NAS (Network Attached Storage), con la finalidad de tener una estrategia de alta disponibilidad, escalable, segura para reducir riesgos en la operación, como parte de los procesos.

V. CONCLUSIONES

La experiencia en la generación, implementación y administración de un lago de datos y areneros en el INEGI genera valor agregado a los procesos basados en analítica y ciencia de datos, considerando grandes volúmenes de información estadística y geográfica en diferentes formatos. Asimismo, consolida un repositorio para generar productos y servicios orientados a visualizaciones cuantitativas y cualitativas que permitan la toma de decisiones.

AGRADECIMIENTOS

Grupo colaborativo del Laboratorio de Ciencia de Datos INEGI

- Elio Atenógenes Villaseñor
- Abel Alejandro Coronado Iruegas
- Alejandro Esteban Pimentel Alarcón
- Ranyart Rodrigo Suárez Ponce
- Alejandra Figueroa Martínez
- Amado Esquer Martínez
- Víctor Silva Cuevas
- Irving Gibran Cabrera Zamora
- Edgar Oswaldo Díaz

REFERÊNCIAS BIBLIOGRÁFICA

- [1] Anejionu, O. C. D., Thakuriah, P. (Von), McHugh, A., Sun, Y., McArthur, D., Mason, P., & Walpole, R. (2019). Spatial urban data system: A cloud-enabled big data infrastructure for social and economic urban analytics. *Future Generation Computer Systems*, 98, 456–473. <https://doi.org/10.1016/j.future.2019.03.052>
- [2] Ashofteh, A., & Bravo, J. M. (2021). Data science training for official statistics: A new scientific paradigm of information and knowledge development in national statistical systems. *Statistical Journal of the IAOS*, 37(3), 771–789. <https://doi.org/10.3233/sji-210841>
- [3] Díaz, O., Muñoz, M., & Mejía, J. (2019). Responsive infrastructure with cybersecurity for automated high availability DevSecOps processes. 2019 8th International Conference On Software Process Improvement (CIMPS), 1–9. <https://doi.org/10.1109/CIMPS49236.2019.9082439>
- [4] Jimenez-Marquez, J. L., Gonzalez-Carrasco, I., Lopez-Cuadrado, J. L., & Ruiz-Mezcua, B. (2019). Towards a big data framework for analyzing social media content. *International Journal of Information Management*, 44, 1–12. <https://doi.org/https://doi.org/10.1016/j.ijinfomgt.2018.09.003>
- [5] Llave, M. R. (2018). Data lakes in business intelligence: reporting from the trenches. *Procedia Computer Science*, 138, 516–524. <https://doi.org/10.1016/j.procs.2018.10.071>
- [6] Mankins, J. (1995). *Technology Readiness Level – A White Paper*.
- [7] Sfaxi, L., & Ben Aissa, M. M. (2020). DECIDE: An Agile event-and-data driven design methodology for decisional Big Data projects. *Data and Knowledge Engineering*, 130(July 2019), 101862. <https://doi.org/10.1016/j.datak.2020.101862>
- [8] Documentación para instalación de la herramienta en la capa de interoperabilidad llamada GitLab (<https://docs.gitlab.com/ee/install/requirements.html>)
- [9] Documentación para instalación de la herramienta en la capa de interoperabilidad llamada MLflow (<https://mlflow.org/docs/latest/quickstart.html#installing-mlflow>)
- [10] Documentación para la instalación de la herramienta en la capa de interoperabilidad llamada Kedro y que permite la conexión con MLflow (https://kedro-mlflow.readthedocs.io/en/stable/source/02_installation/index.html)
- [11] Documentación para la instalación e implementación de los módulos para el lenguaje Python (<https://docs.python.org/es/3/installing/index.html#installing-into-the-system-python-on-linux>)
- [12] Documentación para implementar el IDLE llamado Jupyter Lab utilizado como herramienta para interoperar con python (<https://docs.jupyter.org/en/latest/install.html>)
- [13] Documentación para implementar la herramienta de almacenamiento llamada Minio con el protocolo de transferencia S3 (<https://docs.min.io/minio/baremetal/>)
- [14] Documentación para implementar el componente que permite la conectividad con fuentes de información relacionadas con gestores de

datos llamada trino
(<https://trino.io/docs/current/installation/deployment.html>)

- [15] Documentación para implementar el componente que permite la virtualización de los datos llamada Hive
(<https://cwiki.apache.org/confluence/display/Hive/GettingStarted#GettingStarted-InstallingHivefromaStableRelease>)
- [16] Documentación para implementar las bibliotecas de código que permiten la gestión de analítica y ciencia de datos
(<https://docs.python.org/es/3/library/>)

- [17] Documentación para instalar la herramienta que permite la visualización llamada Superset (<https://superset.apache.org/docs/installation/installing-superset-from-scratch>)

- [18] Documentación para implementar código basado en javascript que permite la visualización de datos llamada D3js (<https://d3js.org/>)