



INICIATIVA DE ESTRATEGIA DIGITAL

1.- Arquitectura de Datos Electrónicos: Lago de Datos Institucional

Este documento propone un plan de acción para implementar una plataforma que integre procesos, roles y tecnologías de acceso a datos digitales de manera transversal, con el objetivo de modernizar y mejorar los proyectos institucionales orientados a la producción, investigación, análisis y difusión de la información estadística y geográfica generada por el Instituto, incorporando estrategias digitales y nuevas tecnologías.

CONTENIDO

- 1. Resumen Ejecutivo 3
 - 1.1. Presentación 3
 - 1.2. Objetivos 3
 - 1.3. Beneficios Esperados 4
 - 1.4. Aprovechamiento del lago de datos en las fases del proceso de producción 6
- 2. Diagnóstico..... 7
 - 2.1. Análisis de la situación..... 7
 - 2.2. Limitaciones 11
 - 2.3. Retos: hacia un Lago de Datos Institucional 13
- 3. Plan de Implementación 16
 - 3.1. Aspectos clave..... 17
 - 3.2. Fases de Implementación..... 22
 - 3.3. Plan de Acción 26
 - 3.4. Actores clave..... 32
 - 3.5. Entregables..... 33
 - 3.6. Consideraciones Adicionales..... 36
- 4. Seguridad y Privacidad en Lagos de Datos..... 37

1. RESUMEN EJECUTIVO

1.1. PRESENTACIÓN

El Instituto Nacional de Estadística y Geografía (INEGI o Instituto) es el encargado de coordinar el Sistema Nacional de Información Estadística y Geográfica (SNIEG) y de generar, recopilar y difundir información estadística y geográfica que sirva para el desarrollo del país y la toma de decisiones informadas. Su labor es fundamental para entender la realidad nacional y contribuir al diseño de políticas públicas efectivas, proporcionando datos clave para el análisis social, económico y ambiental.

Para lograr su misión, es fundamental que se diseñen e instrumenten estrategias para que, mediante la aplicación y uso de las tecnologías adecuadas, se mantengan vigentes sus procesos y permitan transformar sus productos y servicios de información. Esto implica promover la innovación continua, a través de la incorporación de tecnologías emergentes, no sólo para agilizar la operación de las áreas del INEGI que generan productos y servicios con datos digitales, sino también para satisfacer las necesidades de las personas responsables de tomar decisiones y de la sociedad en general, proporcionándoles información que puedan consumir de manera flexible y en diversos ecosistemas digitales.

La Coordinación General de Estrategia Digital (CGED) reconoce que la gestión de información, mediante medios electrónicos, es un componente tecnológico clave para que el Instituto continúe siendo una institución líder, innovadora y cumpla de forma eficiente con sus funciones y objetivos. Por ello, en ejercicio de sus atribuciones, propone la siguiente estrategia digital:

Establecer un lago de datos como repositorio central escalable, flexible y rentable para gestionar grandes volúmenes de datos estructurados, semiestructurados y no estructurados en sus formatos nativos, con el fin de habilitar el análisis de datos avanzados. Esto permitirá enfrentar al instituto el crecimiento exponencial de la información, obtener conocimientos a escala y avanzar en su transformación digital.

Este documento presenta una propuesta de la arquitectura inicial del lago de datos basada en el análisis de la situación actual que presenta el Instituto, así como un plan de acción para la construcción de un Lago de Datos Institucional. Incluye metas específicas, plazos de ejecución, responsables de cada fase y la documentación mínima necesaria para estructurar y guiar las acciones de la estrategia. La iniciativa busca incorporarse a la plataforma tecnológica del Instituto conformada por plataformas transversales que, en su conjunto, facilitan flujos de trabajo colaborativos que gestionen grandes volúmenes de datos estadísticos y geográficos, habilitando análisis avanzados y esquemas para un intercambio más eficiente de la información.

1.2. OBJETIVOS

Se ha determinado una ruta a seguir para la que se establece el siguiente objetivo estratégico y los contributivos.

Objetivo Estratégico

Fortalecer la Plataforma Transversal de Información Electrónica para proporcionar un entorno de datos que satisfaga necesidades presentes y futuras de las Unidades Administrativas (UA) que generan información estadística y geográfica, en materia de producción, integración, difusión, análisis y conservación de las diversas fuentes de datos, que permitan optimizar el valor de la información, haciéndola accesible, comprensible y relevante para las personas usuarias.

Objetivos Contributivos

- Construir una arquitectura de datos que permita centralizar la **gestión de datos estructurados y no estructurados** provenientes de diversas fuentes de información.

- Implementar una **plataforma de software para la catalogación de datos**, que asegure condiciones óptimas de gobernanza, acceso y seguridad de la información. Esta plataforma debe considerar una gestión adecuada de metadatos y proporcionar glosarios que describan los conceptos, facilitando a las personas usuarias una comprensión integral de la información y sirviendo como herramientas para establecer entornos de datos enlazados.
- Proveer de un entorno de datos que favorezca la **analítica avanzada, impulse la creación de nuevos productos y servicios**, y mejore la capacidad del Instituto para adaptarse a las necesidades emergentes.
- Adoptar un ambiente tecnológico colaborativo y propicio, que facilite la **integración de sistemas y datos de diferentes fuentes, favoreciendo la interoperabilidad** entre aplicaciones y plataformas dentro del Instituto.
- Promover una **cultura de innovación en el INEGI**, entendida como uno de los pilares clave para la modernización institucional, abriendo nuevas posibilidades de colaboración e impulsando el desarrollo de técnicas innovadoras para la producción, integración, difusión y análisis de información.

1.3. BENEFICIOS ESPERADOS

Para gestionar grandes organizaciones de manera eficiente, resulta esencial una arquitectura tecnológica que permita organizar y operar los recursos de manera óptima. En el caso del INEGI, la implementación de una arquitectura basada en plataformas transversales es clave para responder a las demandas tecnológicas actuales. Estas plataformas agrupan servicios y recursos especializados que, al integrarse, facilitan la gestión de la infraestructura de almacenamiento y los servicios analíticos, proporcionando soluciones rápidas y eficientes.

Dentro de este enfoque, la implementación de un Lago de Datos Institucional se presenta como una estrategia clave para aprovechar las fuentes y bases de datos actuales y futuras, ofreciendo un entorno colaborativo, diseñado no solo para almacenar y procesar grandes volúmenes de información estructurada y no estructurada, sino también para facilitar su reutilización y uso compartido. Esta estrategia digital busca optimizar el acceso y el uso de la información por parte de distintas áreas del INEGI para mejorar la toma de decisiones. Además, facilita la creación de un entorno tecnológico que promueva la colaboración multidisciplinaria favoreciendo así la mejora de las fases de captación, procesamiento, análisis de la producción y difusión del proceso de producción de la información. Al estar integrado con las plataformas transversales, el LDI minimiza la duplicación de esfuerzos y facilita el uso compartido de la información, potenciando así la eficiencia operativa y el valor de los datos disponibles.

A continuación, se detallan los beneficios clave que esta plataforma ofrecerá al Instituto:

1. **Consolidación lógica y colaborativa de información estadística y geográfica.**
 - a. **Visión unificada de datos:** mediante una plataforma colaborativa que permita la interoperabilidad entre datos provenientes de diversas fuentes, temáticas y formatos, se facilita la integración de productos y servicios que involucren todas las fases del proceso de producción de información estadística y geográfica, maximizando con ello el valor y uso de la información.
 - b. **Reducción de duplicación:** al fomentar un entorno colaborativo donde las distintas áreas sustantivas del Instituto compartan y accedan a datos de manera coordinada, se minimiza la duplicación de datos y los esfuerzos de integración, permitiendo que las personas usuarias y sistemas trabajen con la misma información y se simplifique su gestión.
2. **Flexibilidad en el manejo de datos.**
 - a. **Tipos de datos:** permitirá almacenar y procesar tanto datos estructurados como no estructurados en un solo ecosistema, brindando flexibilidad para realizar diferentes tipos de análisis y consultas.
 - b. **Escalabilidad:** estará diseñado para manejar grandes volúmenes de datos y escalar de manera eficiente según las necesidades.

3. Optimización del rendimiento analítico.

- a. **Análisis avanzado:** ofrece capacidades para aplicar técnicas avanzadas de análisis y aprendizaje automático sobre grandes conjuntos de datos, permitiendo hacer hallazgos más profundos y precisos.
- b. **Consultas eficientes:** gracias a la combinación de características de los lagos de datos y los almacenes de datos, es posible realizar consultas simples y complejas sin sacrificar el rendimiento.

4. Mejora en la toma de decisiones.

- a. **Descubrimientos basados en datos:** la analítica avanzada de grandes volúmenes y variedad de datos permite obtener nuevos hallazgos, lo que agiliza y facilita la toma de decisiones.
- b. **Acceso en tiempo real:** la capacidad de procesar y analizar datos de diferentes fuentes y en tiempo real, o casi en tiempo real, permite una respuesta más rápida a los cambios y eventos operativos.

5. Eficiencia operativa.

- a. **Automatización de procesos:** las capacidades de, integrar datos de diversas fuentes y formatos y el análisis avanzado, permiten automatizar procesos operativos, lo que mejora la eficiencia y favorece a la toma de decisiones de manera más rápida.
- b. **Reducción de costos:** al consolidar datos en una sola plataforma, es posible que se lleguen a reducir las necesidades de mantener múltiples sistemas de almacenamiento y procesamiento, lo que en su momento podría reducir costos operativos y de infraestructura.

6. Mejora en la calidad de los datos.

- a. **Integridad y consistencia:** centralizar los datos ayuda a mantener la integridad y consistencia de la información, ya que se reduce la probabilidad de errores y discrepancias entre diferentes fuentes de datos.
- b. **Gobernanza y seguridad:** facilitar la implementación de políticas de gobernanza de datos, a través de herramientas de catalogación de datos (Data Catalog) y medidas de seguridad, contribuye a que los datos se manejen de manera adecuada y cumplan con las normativas y criterios establecidos por el o las áreas encargadas de la gestión de gobierno de datos y seguridad de la información.

7. Favorece la innovación.

- a. **Acceso a datos diversos:** tener acceso y una visión más completa de la diversidad de información disponible, puede inspirar ideas y soluciones innovadoras para la incorporación de nuevos productos y servicios.

1.4. APROVECHAMIENTO DEL LAGO DE DATOS EN LAS FASES DEL PROCESO DE PRODUCCIÓN

Una arquitectura de lago de datos, como la que se plantea, tiene el potencial de beneficiar a las fases del proceso de producción de información estadística y geográfica, fomentando la adopción y el empleo de nuevas técnicas en fases como la captación, procesamiento, análisis de la producción y difusión de la información. Esto permite optimizar tiempos y recursos. Su desarrollo e implementación pueden comenzar operando en paralelo con los procesos actuales, con el objetivo de integrarse de manera gradual en la producción de información. En la siguiente lista, se presentan algunos ejemplos específicos de cómo el LDI puede aportar beneficios a distintas fases del proceso de producción de información:

1. Captación:

- a. **Disponibilidad inmediata de datos para análisis oportuno:** facilita la ingesta de datos, estructurados y no estructurados, en su estado original y sin tratamiento previo, permitiendo el acceso instantáneo para el análisis y armonización estructural, lo cual es clave para la toma de decisiones en tiempo real.
- b. **Integración de datos semi estructurados de registros administrativos:** permite captar datos de múltiples registros en formatos variados (*textos*, *JSON*, *XML*), estandarizando y organizando la información en un único repositorio.
- c. **Automatización del flujo de datos:** utiliza herramientas para la extracción, transformación y carga de datos (ETL por sus siglas en inglés) desde fuentes administrativas hacia el lago, minimizando errores manuales y garantizando la actualización continua.
- d. **Análisis en tiempo real:** procesa rápidamente datos semi estructurados, habilitando el análisis en tiempo real de registros administrativos, que pueden incluir cambios frecuentes, como en censos y trámites gubernamentales.

2. Procesamiento:

- a. **Preprocesamiento de datos semi estructurados:** facilita la limpieza y organización de datos semi estructurados en una forma más útil para el análisis mediante herramientas avanzadas para identificar y manejar datos faltantes, duplicados o en formatos irregulares.
- b. **Integración y transformación de grandes volúmenes de datos:** permite la integración, transformación y procesamiento eficiente de grandes y diversos conjuntos de datos, tales como aquellos integrados a través del Sistema de Gestión de Archivos del Acervo de Registros Administrativos (SIGA-ARA) y proporcionados por las Unidades del Estado del SNIEG.
- c. **Enriquecimiento de datos:** permite combinar datos semi estructurados de registros administrativos con otros datos estructurados y no estructurados, mejorando el contexto de análisis y permitiendo la creación de variables derivadas.
- d. **Uso de técnicas avanzadas:** aplica algoritmos de aprendizaje automático para clasificar y categorizar datos semi estructurados, lo que mejora la calidad de los datos y extrae información útil que no es fácilmente accesible en su formato original.
- e. **Gestión de grandes volúmenes:** facilita el procesamiento escalable y eficiente de datos masivos provenientes de registros administrativos, ofreciendo almacenamiento a gran escala con procesamiento distribuido.

3. Análisis de la Producción:

- a. **Comparación con datos históricos y de otras fuentes:** permite analizar resultados en relación con datos históricos y de otras fuentes en un solo entorno, facilitando la detección de inconsistencias y el análisis de tendencias.
- b. **Centralización de indicadores de calidad:** almacena indicadores de calidad y metadatos de cada proceso, apoyando la evaluación de la calidad y la confiabilidad de los datos.

4. Difusión:

- a. **Publicación segura y accesible:** facilita la publicación de datos y metadatos de manera segura, integrándose con plataformas de difusión para la disponibilidad de la información al público y personas usuarias internas.
- b. **Gestión de acceso y confidencialidad:** controla los niveles de visualización de la información según el perfil de la persona usuaria, asegurando la confidencialidad y el cumplimiento de las normativas.

2. DIAGNÓSTICO

El diagnóstico presenta un análisis detallado de la situación actual, identifica las principales limitaciones de la arquitectura vigente y plantea los retos que deben abordarse para avanzar hacia una gestión de datos más eficiente, interoperable y orientada a la toma de decisiones.

Además, para contextualizar los hallazgos y propuestas del diagnóstico, se ofrece un marco conceptual e internacional en los anexos correspondientes. El **Anexo 1** analiza la Plataforma Tecnológica del INEGI y su relación con la estrategia del Lago de Datos Institucional (LDI). El **Anexo 2** aborda la evolución de las arquitecturas de datos institucionales, destacando la transición hacia soluciones que integran lagos de datos con almacenes de datos. El **Anexo 3** presenta casos de éxito en Oficinas Nacionales de Estadística avanzadas, subrayando cómo han aprovechado arquitecturas similares para transformar y optimizar sus procesos. El **Anexo 4** detalla el aprovechamiento del Lago de Datos Experimental en el INEGI y los aprendizajes derivados de su implementación. El **Anexo 5** compara la arquitectura actual del Instituto con la situación propuesta, enfatizando los beneficios esperados. Finalmente, el **Anexo 6** identifica los nuevos roles que deberán asumir las Unidades Administrativas para garantizar la adopción e implementación exitosa de la estrategia del LDI.

2.1. ANÁLISIS DE LA SITUACIÓN

El propósito central de esta sección es evaluar las capacidades actuales del Instituto en la gestión de datos y su alineación con los objetivos estratégicos de la iniciativa del Lago de Datos Institucional (LDI). Para contextualizar y fundamentar este análisis, se integran marcos conceptuales e internacionales que sirven de referencia en el diseño y la implementación de arquitecturas de datos modernas, asegurando que las propuestas estén alineadas con las mejores prácticas y experiencias internacionales comparables.

Con base en este análisis, se plantea la necesidad de evolucionar hacia una arquitectura de datos más integrada y eficiente. Esta transición implica consolidar las arquitecturas existentes hacia un Lago de Datos Institucional de uso transversal, incorporando una capa robusta de gobierno de datos y metadatos, con el objetivo de conformar un ecosistema de datos colaborativo.

2.1.1. Marcos y componentes de la arquitectura de lago de datos.

La gestión de grandes volúmenes de datos heterogéneos para el análisis de datos modernos ha llevado a la necesidad de implementar los lagos de datos. Aunque existen trabajos sobre aspectos individuales de los lagos de datos, no había una arquitectura integral hasta la introducción del Marco de Arquitectura de Lagos de Datos (DLAF).

El DLAF es un marco integral que apoya la definición de arquitecturas para lagos de datos, abarcando nueve aspectos arquitectónicos clave y sus interdependencias. Este marco ayuda a elegir conceptos apropiados para cada aspecto, proporcionando una guía completa para configurar una arquitectura de lago de datos. Los nueve aspectos arquitectónicos clave (perspectivas de un lago de datos) que el DLAF considera son:

- A. **Infraestructura:** Define los sistemas y herramientas concretas sobre las que se construye el lago de datos.
- B. **Almacenamiento de Datos:** Se refiere a dónde se almacenan los datos, considerando aspectos como la escalabilidad, la rentabilidad y la durabilidad. Incluye tipos básicos de almacenamiento como bruto inmutable, optimizado y bases de datos scratch, y puede optar por soluciones en la nube (AWS, Azure) o locales (on-premise).
- C. **Flujo de Datos:** Describe cómo los datos se mueven dentro del lago de datos, incluyendo la ingesta mediante capacidades como ingesta por lotes, transmisión en tiempo real y captura de cambios de datos (CDC).
- D. **Modelado de Datos:** Explica cómo se estructuran los datos, una decisión que está influenciada por el sistema de almacenamiento seleccionado.
- E. **Organización de Datos:** Se centra en cómo se organizan los datos para una gestión y uso eficientes, incluyendo conceptos como la segmentación de datos, mallas de datos semánticas y arquitecturas de zonas de datos.

- F. **Procesos de Datos:** Involucra los procesos para transformar y analizar los datos, como los *pipelines* de procesamiento (ej. procesos ETL para mensajes).
- G. **Gestión de Metadatos:** La información sobre los datos (fuente, formato, uso, entre otros) que es crucial para su descubribilidad y accesibilidad.
- H. **Seguridad y privacidad de datos:** Un aspecto conceptual esencial para garantizar la conformidad legal y la alineación con los objetivos comerciales, que debe integrarse desde las fases iniciales del diseño para lograr implementaciones exitosas.
- I. **Calidad de Datos:** Otro aspecto conceptual crucial para asegurar la usabilidad de los datos y prevenir que el lago se convierta en un "data swamp" o pantanos de datos (repositorios donde los datos son inutilizables por mala organización, gobernanza o accesibilidad).

Es importante destacar que las decisiones sobre uno de estos aspectos del DLAF afectan directamente a los demás; por ejemplo, la elección del almacenamiento influye en el modelado de datos, y los aspectos de seguridad y calidad impactan en todos los demás.

Además del DLAF, las arquitecturas de lago de datos suelen incluir componentes centrales como:

- **Capa de Ingesta:** Punto de entrada para la recolección e integración de datos.
- **Capa de Almacenamiento:** Donde los datos se almacenan en su formato crudo.
- **Capa de Procesamiento:** Transforma los datos crudos en información significativa, utilizando herramientas analíticas y modelos de *machine learning*.
- **Capa de Gobernanza:** Mantiene la calidad, seguridad y cumplimiento normativo de los datos.

2.1.2. Diseño de una Arquitectura de Datos Moderna y Unificada

Una arquitectura de datos moderna y unificada proporciona el plan de diseño integral para gestionar datos a lo largo de su ciclo de vida en un sistema o grupo de sistemas. Este tipo de arquitectura se enfoca en dos áreas principales: la ingeniería de datos (que sienta las bases para la organización y el mantenimiento de los datos) y la ciencia de datos (que aprovecha los datos para generar *insights*).

Para diseñar o actualizar una arquitectura de datos moderna, se recomienda:

- I. **Evaluar el estado actual** de las herramientas y sistemas existentes en la organización, y cómo se relacionan entre sí.
- II. **Identificar beneficios y puntos de dolor** mediante entrevistas con las partes interesadas.
- III. **Definir objetivos de negocio claros** y las preguntas importantes que la organización necesita responder a través de los datos.
- IV. **Establecer políticas, reglas, estándares y modelos** que gobiernen la recolección, almacenamiento, gestión, procesamiento y uso de datos.
- V. **Garantizar la consistencia** en la recolección de datos y seleccionar las herramientas de visualización apropiadas.

Con base en el marco DLAF y en las recomendaciones para el diseño de arquitecturas de datos modernas, resulta indispensable una evolución estratégica en la arquitectura de datos del Instituto, que permita responder de manera efectiva a los desafíos actuales y futuros en la gestión de datos.

2.1.3. Evolución de la Arquitectura de Datos del Instituto


En el contexto específico del Instituto, la evolución de la arquitectura de datos ha sido un proceso continuo. Inicialmente, el Almacén de Datos comenzó a operar en 2002 con el objetivo de consolidar bases de datos estadísticas estructuradas. Posteriormente, se integró una arquitectura de dos niveles con la adición del Lago de Datos

Experimental del Laboratorio de Ciencia de Datos y Métodos Modernos de Información (LCID) en 2019, enfocado en el almacenamiento de datos estructurados y no estructurados para analítica avanzada experimental.

El estado que impulsa la estrategia actual es la implementación de un Lago de Datos Institucional que vinculará ambas arquitecturas. Este LDI incorporará una capa de gobierno de datos y metadatos, buscando ofrecer las condiciones adecuadas para construir un ecosistema de datos de uso transversal y colaborativo. Esta iniciativa busca integrar los ecosistemas de datos existentes en un ambiente colaborativo de uso transversal, que ofrezca las condiciones adecuadas de gobierno, acceso y seguridad a las Unidades Administrativas (UA) del Instituto. El objetivo es permitir a las UA trabajar con datos en un entorno abierto, combinar datos en diferentes formatos y aplicar analítica utilizando inteligencia artificial, aprendizaje automático, inteligencia de negocios e ingeniería de datos en apoyo a los procesos institucionales, la generación de nuevos productos y servicios y la toma de decisiones.

La **Figura 1** muestra la evolución de la arquitectura de datos en el Instituto, enfocada a la consolidación de información, así como la dirección que se espera tomar mediante la iniciativa propuesta.

Figura 1. Flujo de evolución hacia la tecnología de Lago de Datos en el Instituto.



Fuente: Elaboración LCID-DGI

En las siguientes secciones, se explican con mayor detalle los elementos y características de este flujo.

Almacén de Datos.

En el segundo trimestre de 2022 surge en el INEGI el Almacén de Datos, con el objetivo de consolidar las bases de datos de información estadística, que hasta entonces se mantenían como subsistemas independientes en las diferentes áreas funcionales del Instituto. Su propósito fue ofrecer un entorno colaborativo diseñado para almacenar y procesar grandes volúmenes de información estructurada y no estructurada, así como para facilitar su reutilización y uso compartido, en apoyo a la toma de decisiones y generación de productos de información.

Este repositorio de datos opera hoy día sobre una plataforma tecnológica que permite la gestión de información estructurada. En él, se integran algunos de los conjuntos de datos resultado de la fase de Análisis de la Información del Modelo de Producción de Información Estadística y Geográfica (MPEG). Es relevante señalar que los temas que aborda son sólo de la materia estadística, es decir, no integra información geográfica.

Sus componentes:

- **Datos:** son aquellos que provienen de la fase de Análisis de la producción, cuyos formatos son invariablemente estructurados.
- **Extracción, transformación y carga:** representa los módulos que cumplen la función de extraer la información de las fuentes de datos para cargarla en los modelos de base de datos previamente definidos (esquemas de datos) para facilitar la consulta, análisis y la generación de productos.
- **Capa de datos y metadatos:** se compone de conjuntos de datos organizados en áreas temáticas abstractas con versiones variables en el tiempo de los mismos registros, con un nivel apropiado de granulación o detalle para que sean útiles y accesibles para su consulta y análisis. Esta capa de datos incluye los metadatos de todos aquellos conjuntos de datos que se almacenan para que se puedan entender y encontrar fácilmente.
- **Herramientas de consulta y análisis:** se refiere a las herramientas de inteligencia de negocios y de reportes, utilizadas por las y los analistas para interactuar con los datos, extraer información y crear vistas fáciles de usar, como informes, tableros de mando, tablas y gráficos.

Lago de Datos Experimental del Laboratorio de Ciencia de Datos

En el cuarto trimestre del año 2019, se constituye el Laboratorio de Ciencia de Datos (LCID) por parte de la DGIAl, con el objetivo de contribuir al fortalecimiento del INEGI y del SNIEG. Su propósito es promover la incorporación de métodos y técnicas de ciencia de datos en la producción de información estadística y geográfica, así como la definición de las políticas para su funcionamiento.

La operación del Lago de Datos Experimental se lleva a cabo en una plataforma tecnológica asignada al LCID, diseñada para la integración de diversas fuentes de información, tanto estructuradas como no estructuradas. Esta plataforma permite el aprovechamiento de los datos mediante métodos y técnicas de ciencia de datos (analítica avanzada), con el objetivo de apoyar la investigación y la generación de estadísticas experimentales. Las partes que conforman el Lago de Datos del LCID son:

- **Fuentes de datos:** se refieren a las fuentes de información que contienen datos en diversos formatos, que pueden ser estructurados, no estructurados y semiestructurados.
- **Extracción, carga y transformación:** son los módulos que cumplen la función de extraer la información desde su origen y se almacenan “tal cual” primero y se transforman, analizan y procesan en una etapa posterior.
- **Capa de datos:** es donde se almacena la información proveniente de las fuentes de datos. Ha sido diseñada para trabajar con una amplia gama de datos que cubren una gran variedad de tipos y de volúmenes.
- **Preparación de datos y validación:** se refiere a la catalogación, limpieza, formateo, transformación y enriquecimiento de datos. Este proceso garantiza que los datos estén en condiciones de ser utilizados para el análisis, mediante métodos de ciencia de datos y/o algoritmos avanzados de aprendizaje automático.
- **Métodos y enfoques para el análisis de datos en el Lago de Datos del LCID:** En el entorno del Lago de Datos del LCID, se emplean principalmente dos enfoques avanzados para la consulta, explotación y procesamiento de la información:
 - **Ciencia de datos:** Se refiere al uso de métodos científicos, procesos y sistemas que permiten comprender en profundidad las características y el comportamiento de grandes volúmenes de datos. Este enfoque facilita la identificación de patrones y tendencias en fenómenos reales, apoyando la toma de decisiones basada en evidencia.
 - **Aprendizaje automático:** Consiste en la aplicación de algoritmos avanzados que incorporan tecnologías como el aprendizaje profundo, las redes neuronales y el procesamiento del lenguaje natural. Estos métodos se utilizan tanto en aprendizaje supervisado como no supervisado, permitiendo extraer conocimiento de la información disponible y mejorar continuamente los modelos analíticos a partir de los datos existentes.

En el escenario actual, la información albergada en el Almacén de Datos puede ser, y ha sido aprovechada como fuente de información para el Lago de Datos del LCID. Así mismo, sería parcialmente posible que ciertos datos resultantes de los procesos de ciencia de datos y analítica avanzada puedan ser extraídos, transformados y cargados (ETL por sus siglas en inglés) en el Almacén de Datos, como información estructurada, conformando modelos de datos predefinidos para su aprovechamiento. No obstante, estos dos repositorios actualmente operan de forma independiente, bajo reglas de acceso y seguridad distintas. Por lo que, bajo este escenario, la información se duplicaría representando un riesgo de consistencia entre las versiones de datos utilizadas.

2.2. LIMITACIONES

El modelo actual de arquitectura de datos en el Instituto presenta una serie de limitaciones significativas que impactan directamente la gestión, integración y explotación eficiente de la información estadística y geográfica. Estas limitaciones, tanto a nivel general como específicas para el Almacén de Datos y el Lago de Datos Experimental, dificultan el aprovechamiento óptimo de la información y la eficiencia en los procesos de datos del Instituto. Reconocer y detallar estos desafíos es el primer paso para justificar la transición hacia una arquitectura más unificada y moderna.

2.2.1. Limitaciones Generales de la Arquitectura Actual

La arquitectura actual del Instituto se basa en un modelo de dos niveles, donde el Almacén de Datos y el Lago de Datos Experimental operan de forma independiente. Esta separación genera varios desafíos y añade complejidad a la gestión de datos, incluyendo:

- **Coherencia y Duplicación de Datos:** La independencia de las plataformas dificulta la coherencia entre la información contenida en el Lago de Datos Experimental y el Almacén de Datos, lo que puede llevar a duplicidad de información y, consecuentemente, a un riesgo de inconsistencia entre las versiones de datos utilizadas. Esta duplicación de datos también se traduce en un mayor costo de almacenamiento.
- **Gestión Diferenciada y Madurez de Proyectos:** El Almacén de Datos, gestionado por la DGI, responde a una lógica de procesos productivos, mientras que el Lago de Datos Experimental, bajo la DGIAI, se orienta a la investigación. Aunque los proyectos del Lago de Datos Experimental se están acercando a un grado de maduración que requiere su transferencia a un ambiente productivo, esta dualidad en la administración y enfoque dificulta una visión y gestión unificada de los datos.
- **Dependencia y falta de Autonomía de las Unidades Administrativas (UA):** Las UA requieren administrar, procesar y explotar su información sin la intervención de un intermediario que pueda reducir la flexibilidad y alargar los tiempos de sus procesos. La centralización de servicios de ingesta, analítica avanzada y generación de productos de información en la DGIAI para el Lago de Datos Experimental, y en la DGI para el Almacén de Datos, concentra el conocimiento y la experiencia en puntos específicos, lo que puede reducir la capacidad de respuesta y dificultar la colaboración y la innovación en otras áreas del Instituto. Este enfoque de "guardián" genera cuellos de botella operativos y limita la escalabilidad.
- **Disparidad y Silos de Datos:** La existencia de recursos informáticos similares en las UA ha favorecido la creación de múltiples almacenes de datos bajo procedimientos y reglas propias, lo que resulta en la proliferación de silos y duplicidad de datos. Esta disparidad y distribución de datos dificulta la captura de toda la información necesaria para un análisis efectivo.
- **Riesgo de "Data Swamps" (pantanos de datos):** Una de las limitaciones más críticas en las implementaciones de lagos de datos es el riesgo de que se conviertan en "data swamps" (pantanos de datos), donde los datos se vuelven inutilizables debido a una organización, gobernanza o accesibilidad deficientes. Esto se agrava si no se establecen estructuras claras de propiedad de datos, lo que está relacionado con la falta de gobernanza unificada mencionada en el contexto del Instituto.
- **Costo de Incidentes de Seguridad:** Los repositorios de datos centralizados, si no se gestionan adecuadamente, pueden enfrentar costos significativamente más altos por incidentes de seguridad. La falta de

una gobernanza de TI unificada y controles de seguridad adecuados en el Lago de Datos Experimental exacerba estos riesgos.

2.2.2. Limitaciones Específicas del Almacén de Datos

- **Centralización de Servicios y Flexibilidad Reducida:** Los servicios de integración de datos y generación de productos de información están centralizados en la DGI. Aunque se busca estandarización, la metodología para incorporar información es poco flexible para algunas UA. Esto limita la colaboración y la innovación.
- **Contenidos Desactualizados y Alcance Limitado:** Aunque es un repositorio de versiones definitivas, solo una parte de sus contenidos se actualiza continuamente por parte de las UA. Además, no está preparado para incorporar información geográfica, limitando su aprovechamiento al tema estadístico.
- **Gobierno de Datos Restringido:** A pesar de contar con un alto grado de gobierno de datos (procedimientos de acceso, control de usuarios, bitácoras, control de calidad), su aplicación está limitada y diseñada exclusivamente para los fines y usos de este repositorio, lo que complica su flexibilidad de adaptación a otros contextos o necesidades más amplias.
- **Gestión de Metadatos Centralizada y Propiedad Ambivalente:** Si bien cuenta con un sistema de metadatos para la comprensión de contenidos, su responsabilidad recae en la DGI y no en el área productora de la información, lo que puede afectar la precisión y relevancia de los metadatos. La falta de marcos robustos de metadatos es una causa común de ineficiencias y altos costos en la recuperación de datos.
- **Soporte Limitado para Tipos de Datos y Analítica Avanzada:** Permite el manejo de datos estructurados, con soporte limitado para semiestructurados y nulo para no estructurados. Esto obliga a mantener información en diferentes plataformas según el producto o servicio. Además, la incorporación de analítica avanzada de Inteligencia Artificial (IA) y Machine Learning (ML) es muy difícil, restringiendo su flexibilidad para casos de uso más amplios.

2.2.3. Limitaciones Específicas del Lago de Datos Experimental

- **Separación de Responsabilidades en la Administración:** La infraestructura es administrada por la DGI y la plataforma de software por la DGI AI. Esta separación genera riesgos de seguridad, dificultades para la optimización continua y complejidades operativas debido a la duplicación de esfuerzos o funciones. Compromete también la aplicación de políticas y procesos de gobernanza de TI unificada.
- **Centralización de Servicios de Ingesta y Analítica:** Los servicios de ingesta, analítica avanzada y generación de productos de información están centralizados en la DGI AI. Aunque facilita la gestión, limita la capacidad de respuesta a necesidades específicas de otras áreas y obstaculiza la colaboración.
- **Falta de Gobernanza y Metadatos:** Es una plataforma flexible que admite todos los formatos de datos, pero carece de metadatos y reglas claras y estandarizadas para facilitar la interoperabilidad y la correcta interpretación de los datos. Sin una gobernanza de datos confiable y una gestión de metadatos, un lago de datos puede fácilmente convertirse en un "data swamp" (pantano de datos).
- **Ausencia de Funciones Básicas de Gestión y Seguridad:** Carece de funciones básicas de gestión como transacciones (ACID) y métodos de acceso eficientes como índices para igualar el rendimiento de un almacén de datos. Tampoco cuenta con procedimientos para solicitar acceso, un sistema de control de usuarios y controles de monitoreo de acceso a los datos. Estos elementos son fundamentales para la seguridad y la gobernanza granular de los datos.
- **Falta de un Catálogo de Datos Institucional:** No cuenta con un catálogo de datos que permita conocer la información disponible y sus metadatos, herramientas clave para facilitar la búsqueda, el descubrimiento y la comprensión de los datos. La ausencia de este catálogo reduce significativamente la descubribilidad de la información, lo que genera ineficiencias y costos.

- **Riesgo de Resistencia al Cambio y Madurez Institucional:** Aunque algunas UA están desarrollando perfiles para trabajar en este entorno y tienen acceso, aún carecen de los elementos de gobernanza y seguridad necesarios para habilitarlo como una plataforma colaborativa de alcance institucional. Esto presenta un riesgo de resistencia al cambio por parte de los usuarios acostumbrados a sus sistemas actuales, un desafío común en la adopción de nuevas estrategias de datos.
- **Entorno no Productivo:** El ambiente designado para publicar productos y servicios de información definitivos no forma parte de las Plataformas Tecnológicas para puesta en producción.

2.3. RETOS: HACIA UN LAGO DE DATOS INSTITUCIONAL

La implementación de un Lago de Datos Institucional (LDI) en el Instituto, si bien es una estrategia transformadora, enfrenta una serie de desafíos clave que requieren un enfoque coordinado y estratégico. Estos retos abarcan desde la habilitación de perfiles técnicos especializados y la gestión de la plataforma de software, hasta la definición de un marco sólido de gobernanza de datos y la evaluación de arquitecturas tecnológicas viables. Superar estos obstáculos es fundamental para asegurar que el LDI funcione como un ecosistema eficiente y accesible, capaz de centralizar modelos de datos, procesar y democratizar la información estadística y geográfica.

Los desafíos que el Instituto enfrenta de cara a la adopción o implementación de un Lago de Datos Institucional son los siguientes:

2.3.1. Identificación y Consolidación de la Información:

Es crucial identificar qué información debe confluir y consolidarse en el Lago de Datos Institucional, basándose en los casos de uso que se establezcan en coordinación con las Unidades Administrativas (UA) productoras de información (Véase Anexo 4).

Este proceso es fundamental para evitar que el Lago de Datos se convierta en un pantano de datos, en el que la información se vuelve inutilizable debido a una organización, gobernanza o accesibilidad deficientes.

La disparidad y distribución de los datos, a menudo en silos, dificulta la captura de toda la información necesaria para un análisis efectivo, un reto que el LDI debe superar al consolidar las diversas fuentes. La modernización de sistemas heredados es una tarea compleja que requiere planificación y consideración de capas de interfaz de usuario, datos y funciones.

2.3.2. Desarrollo de Capital Humano y Habilitación de Nuevos Perfiles Técnicos:

Es imperativo habilitar en las UA productoras de información los nuevos perfiles y roles necesarios para que formen parte de este ecosistema de datos.

Asimismo, se requiere conformar un equipo técnico en la DGI para administrar la plataforma de software, con el objetivo de proporcionar un servicio transversal que responda de manera eficiente a las necesidades institucionales, operando bajo un marco de gobernanza de TI.

La complejidad de la infraestructura de datos moderna exige no solo soluciones tecnológicas potentes, sino también personal capacitado y con experiencia en enfoques de gestión de datos y tecnologías de flujo de datos emergentes.

Es esencial la inversión en talento local con habilidades en machine learning, ciencia de datos e ingeniería de datos. Los programas de educación y capacitación deben dotar a los responsables técnicos de estas habilidades técnicas prácticas.

Además, se debe considerar el impacto de la IA y la automatización en la fuerza laboral y definir planes de reentrenamiento laboral.

2.3.3. Valoración y Financiamiento de Arquitecturas Tecnológicas:

Existen varias arquitecturas tecnológicas para implementar un Lago de Datos Institucional, por lo que se deberán valorar las opciones y el costo-beneficio de cada una de ellas.

Entre las opciones a valorar, se debe incluir la arquitectura tecnológica del actual Lago de Datos Experimental para determinar su viabilidad técnica con un enfoque de uso transversal. Este desafío exige la alineación de los recursos con las necesidades actuales para asegurar la continuidad operativa y la integración con otros sistemas institucionales.

Habilitar un ambiente productivo significa retos presupuestales que hay que gestionar en tiempo y forma, ya que están sujetos a autorización. La optimización de almacenamiento y cómputo con gestión por niveles (datos de acceso frecuente en almacenamiento de alto rendimiento y datos menos usados en almacenamiento más económico) y el autoescalado son cruciales para controlar los costos y evitar el gasto excesivo en recursos computacionales. El uso de job bookmarks en procesos ETL también puede reducir costos al evitar el reprocesamiento de datos.

El entrenamiento y desarrollo de la IA aumentan el consumo de energía, lo que requiere algoritmos y una infraestructura más eficiente energéticamente, un factor a considerar en la valoración de arquitecturas.

2.3.4. Establecimiento de un Marco Robusto de Gobernanza y Gestión de Metadatos:

Democratizar su uso para que cada área administre, procese y explote directamente su información requiere habilitar reglas claras de gobierno en materia de estandarización de datos, acceso, uso, documentación y cumplimiento normativo, entre otros.

Uno de los retos más significativos es que el 76% de las organizaciones que implementan lagos de datos reportan problemas de gobernanza, y a menudo fallan en establecer estructuras claras de propiedad de datos.

La falta de marcos robustos de metadatos genera ineficiencias y costos significativos en la recuperación de datos. Es vital habilitar un catálogo de datos que permita gestionar metadatos de datos estructurados y no estructurados, que facilite la búsqueda, descubrimiento y comprensión de datos mediante la catalogación y etiquetado, asegurando la gobernanza y la conformidad con políticas de datos.

La Gestión de Datos Maestros (MDM) es crucial para reducir inconsistencias y establecer un lenguaje común para objetos clave. El uso de marcos de metadatos estandarizados y catálogos de datos acelera la descubribilidad de la información.

2.3.5. Garantía de Seguridad y Privacidad de los Datos:

Los repositorios de datos centralizados pueden enfrentar costos significativamente más altos por incidentes de seguridad.

Asegurar la conformidad legal con normativas y garantizar la seguridad y privacidad de los datos es un reto constante que requiere la implementación de controles de acceso granulares, estrategias de cifrado y técnicas de desidentificación. Además, el registro de auditoría y monitoreo de acceso a los datos, potenciado por IA, es clave para reducir los tiempos de detección y contención de brechas.

2.3.6. Interoperabilidad de Sistemas:

La interoperabilidad es la capacidad de conectar diferentes sistemas y entidades para el intercambio de datos e información. Este es un desafío crítico que abarca múltiples capas:

- **Legal:** Asegurar marcos legales y normativos que permitan el intercambio de información y datos.
- **Organizacional:** Coordinar entre entidades y procesos compartidos.
- **Cultural:** Fomentar una cultura donde los datos se compartan y valoren.

- **Técnica:** Habilitar infraestructuras y aplicaciones que enlacen sistemas y servicios.
- **Semántica:** Garantizar que los sistemas puedan interpretar la información intercambiada de manera significativa y precisa.

Los desafíos específicos de la interoperabilidad incluyen la confianza y seguridad, recursos financieros, tecnología heredada, recursos humanos, calidad de datos, descubribilidad de datos, acuerdos de procesos y coordinación, escalabilidad, niveles variables de madurez digital y liderazgo político.

2.3.7. Gestión del Cambio y Resistencia de Usuarios:

La transición hacia la plataforma de Lago de Datos Institucional podría generar dificultades operativas o de integración, y en algunos casos, generar retrasos en la adopción si no se gestionan adecuadamente las expectativas y necesidades de las distintas personas usuarias.

El riesgo de resistencia al cambio por parte de los usuarios acostumbrados a sus sistemas actuales es real. Por ello, la importancia de incorporar a un equipo de personas usuarias durante la ejecución del plan de acción.

La inversión en capacitación, comunicación e iniciativas culturales es vital para lograr una mayor adopción por parte de los usuarios y asegurar el éxito del proyecto. Fomentar una cultura donde todos los participantes comprendan su rol en la gobernanza es crucial para crear un entorno de responsabilidad colectiva.

3. PLAN DE IMPLEMENTACIÓN

La presente estrategia busca llevar a cabo un plan de acción que permita evolucionar hacia la plataforma del **Lago de Datos Institucional**. Esta evolución se fundamenta en un enfoque pragmático que aprovecha la vasta experiencia y los activos de datos existentes del Instituto. En general, se busca:

1. Apoyarse de la información y experiencia en la implementación y el uso del Almacén de Datos Estadísticos del INEGI (ADE), administrado por la DGI. Este almacén cuenta con un alto grado de gobierno y seguridad de información y está orientado a la consolidación y análisis de datos estructurados.
2. Aprovechar la experiencia del Lago de Datos Experimental (LCID), administrado por la DGI. Este opera sobre una plataforma tecnológica de gestión de datos orientada a la integración de diversas fuentes de información y su aprovechamiento, mediante métodos y técnicas de ciencia de datos (analítica avanzada), con propósitos de investigación.
3. Integrar y evolucionar estos ecosistemas de datos a un ambiente colaborativo de uso transversal, que ofrezca las condiciones adecuadas de gobierno, acceso y seguridad a las Unidades Administrativas (UA) del Instituto. Esto les permitirá trabajar con datos en un entorno abierto, combinar datos en diferentes formatos y aplicar analítica utilizando inteligencia artificial (IA), aprendizaje automático (ML), inteligencia de negocios (BI) e ingeniería de datos en apoyo a los procesos institucionales, la generación de nuevos productos y servicios, y la toma de decisiones.

Con la finalidad de enfocar los esfuerzos y recursos hacia un plan específico y medible, se ha establecido la siguiente meta inicial en el marco de las atribuciones de la Coordinación General de Estrategia Digital (CGED) y la Dirección General de Informática (DGI):

Meta	Atribución
Construir una arquitectura de datos que integre el almacenamiento de datos estructurados y no estructurados, y capacidades de análisis avanzado eficiente, para mejorar la gestión, gobernanza y colaboración en torno a los activos de información del Instituto, facilitando la producción, integración, difusión, análisis e intercambio de productos y servicios de información electrónica.	CGED: I, II, IV y VII DGI: VII, IX, XII, XV

3.1. ASPECTOS CLAVE

Para el logro de esta meta, resultan cruciales los siguientes aspectos clave, los cuales se alinean con los principios de **Arquitectura de Lagos de Datos, Gobernanza del Dato, Seguridad y Privacidad, Automatización y Optimización, Gobernanza de la Inteligencia Artificial e Interoperabilidad de Sistemas**:

3.1.1. Colaboración Interdisciplinaria y Transversal:

La participación de áreas clave como la CGED, DGI, DGAIAI, y las áreas informáticas de las UA, es crucial. Su colaboración y atribuciones garantizarán que los objetivos establecidos estén alineados con los objetivos estratégicos y operativos del Instituto, promoviendo un **enfoque de gobierno integral**.

Este aspecto es fundamental para la creación de un ambiente tecnológico colaborativo y propicio que fomente la integración de sistemas y datos de diferentes fuentes, favoreciendo la interoperabilidad entre aplicaciones y plataformas dentro del Instituto.

CGED	DGI	DGAIAI	Áreas Informáticas de las Unidades Administrativas
Establece un plan de acción para implementar una arquitectura tecnológica de datos de uso transversal, con información de temporalidades diversas y de una amplia cobertura temática, que permitan mejorar la gestión, almacenamiento, procesamiento y análisis de datos en formatos estructurados y no estructurados.	Proporciona la infraestructura y plataformas tecnológicas de hardware y software necesarias para almacenar, procesar, interoperar y visualizar datos de manera eficiente.	Desarrollar la Estrategia de datos que establezca directrices para gestionar el ciclo de vida de los datos y criterios para garantizar transversalidad e interoperabilidad en la información, procurando su simplicidad, reusabilidad, portabilidad y conservación.	Colaborar con la CGED y la DGI en la estructuración, integración, mantenimiento de información de las Unidades Administrativas en el Lago de Datos y colaborar con la DGCSPRI en el diseño y la creación de nuevos servicios y productos de información acordes con las directrices de gobierno de la DGAIAI.

3.1.2. Arquitectura de Datos Inicial y Evolución Continua:


Para el diseño de la arquitectura de datos, se busca aprovechar la experiencia obtenida en la construcción del Lago de Datos Experimental como base para la conformación de un Lago de Datos Institucional.

En la figura 2, el diagrama ilustra la arquitectura de datos inicial, sus componentes clave y la estructura básica para integrar y gestionar de forma segura tanto datos estructurados como no estructurados. Contempla los procesos por los que van fluyendo los datos, que abarcan desde la extracción y carga, pasando por su almacenamiento y procesamiento, hasta su análisis y visualización final.

Para garantizar la seguridad y privacidad en el manejo de los datos, se incorporan prácticas basadas en canales de integración y distribución continua (CI/CD), así como en enfoques tales como *DevSecOps* y *DataSecOps* que permiten integrar prácticas de seguridad en el ciclo de vida de la gestión de datos y el de desarrollo de las aplicaciones que interactúan con este ecosistema de datos.

El diseño de la arquitectura de datos se basará en aprovechar la experiencia obtenida del Lago de Datos Experimental como cimiento para la conformación de un LDI. Esto incluye la integración de un catálogo de datos y la gestión de metadatos para facilitar la interoperabilidad y la correcta interpretación de la información.

Figura 2. Diagrama de Arquitectura Inicial de Lago de Datos.



Fuente: Elaborado por LCID.

La arquitectura inicial del LDI contempla **cinco capas clave** que interactúan de manera integral:

1. Capa de Datos

Es el núcleo de la arquitectura, donde residen los datos crudos y procesados, tanto estructurados como no estructurados. Esta permite almacenar grandes volúmenes de datos sin necesidad de integrarlos a estructuras rígidas, permitiendo un acceso más flexible a la información.

- **Extracción, validación, carga de datos:** Este componente facilita la recolección de información mediante mecanismos como *Web Crawling*, *Web Scraping* y *Web Mining*, a través de APIs (por las siglas en inglés de *Application Programming Interface*). Estos datos son validados y cargados en el sistema.
- **Almacenamiento – Resguardo de datos:** Se refiere al componente que gestiona el depósito de datos en sistemas de almacenamiento como NAS (por las siglas en inglés de *Network Attached Storage*), utilizando protocolos especializados de comunicación como *S3* o *HDFS* (por las siglas en inglés de *Hadoop Distributed File System*).
- **Homologación y transformación de datos:** Proceso de unificación y estandarización de datos provenientes de diversas fuentes. La transformación asegura que los datos sean coherentes y estén listos para el análisis.
- **Integración de datos:** Proceso de agrupación y consolidación de datos depurados que pueden ser integrados en un gestor de datos para realizar consultas y análisis.

2. Capa de Seguridad

Capa que integra los elementos encargados de proteger los datos y asegurar que el acceso a los mismos esté debidamente controlado.

- **Acceso a datos (autenticación - autorización):** Este componente maneja los perfiles de acceso a los datos, metadatos y microdatos, utilizando mecanismos de control de identidades y autenticación robusta.
- **Ingeniería de procesos (*DevSecOps*):** Este componente asegura la seguridad y privacidad de los datos, permitiendo la automatización de procesos de desarrollo con altos estándares de seguridad.
- **Ingeniería de datos (*DataSecOps*):** Permite la gestión de estrategias de seguridad y privacidad en procesos de analítica y ciencia de datos, asegurando el cumplimiento de las políticas de seguridad.

3. Capa de Aplicaciones

Está compuesta por interfaces y herramientas necesarias para que los diferentes tipos de personas usuarias interactúen eficientemente con la capa de datos del Lago de Datos Institucional. Esta capa proporciona una serie de servicios, asegurando que las aplicaciones de diversas áreas puedan aprovechar la funcionalidad del lago sin necesidad de reconstruir toda la infraestructura, promoviendo así una arquitectura colaborativa y distribuida.

Los componentes clave son:

- **Analítica y ciencia de datos:** incluye componentes que permiten aplicar técnicas avanzadas de análisis y ciencia de datos para descubrir patrones, relaciones y tendencias. Estos componentes también integran inteligencia artificial para realizar predicciones y análisis avanzado, accesibles para usuarias y usuarios internos que deseen potenciar sus análisis sin desarrollar nuevas estructuras de datos.
- **Visualización de datos:** proporciona herramientas especializadas para la representación visual de la información mediante diagramas, gráficos y mapas, facilitando la interpretación y comprensión de los datos analizados. Estos servicios están diseñados para ser reutilizables en aplicaciones que buscan agregar visualización de alto nivel.
- **Interoperabilidad y acceso especializado:** una estrategia de interoperabilidad permite que roles específicos como analistas y científicas(os) de datos accedan a la plataforma para realizar análisis avanzados de grandes volúmenes de datos. La interoperabilidad facilita la interacción entre aplicaciones externas y el Lago de Datos, asegurando que estas puedan utilizar los servicios del lago sin necesidad de una integración compleja.
- **Mecanismos de conexión y entrega de información:** Se proporcionan *APIs* y otros servicios de integración que permiten a aplicaciones externas acceder a vistas de información específicas, y también a funcionalidades de analítica y ciencia de datos estadísticos y geográficos. Estas *APIs* permiten que áreas y personas usuarias finales aprovechen los beneficios del Lago de Datos sin romper la estructura modular, promoviendo el desarrollo de aplicaciones distribuidas y descentralizadas que amplíen el valor del lago en diversas soluciones y plataformas.

Esta estructura permite que el Lago de Datos no sea sólo una solución vertical, sino una plataforma central que habilita y potencia las funcionalidades de aplicaciones construidas en diferentes áreas del Instituto.

4. Capa de Infraestructura

Esta capa proporciona la base física y tecnológica sobre la que se construyen las otras capas, incluyendo la red, los servidores de cómputo, de almacenamiento y recursos, ya sea en sitio (*on-premises*), en la nube o híbrido.

En esta arquitectura inicial, la plataforma de cómputo estará alojada en el centro de cómputo (*On-premises*), instalada en una infraestructura local con capacidades de almacenamiento, procesamiento y transferencia de grandes volúmenes de datos estadísticos y geográficos recolectados de fuentes de información internas y externas. En la Figura 3, se muestra la infraestructura inicial propuesta para implementar los componentes de hardware y software para el Lago de Datos Institucional en entorno pre-productivo. Si la valoración de esta infraestructura es satisfactoria, sus características podrán considerarse para el dimensionamiento de una infraestructura que habilite la incorporación de un ambiente productivo.

Figura 3. Diagrama para la infraestructura inicial para implementar el Lago de Datos.



Fuente: Elaboración LCID

5. Capa de Procesos en Entorno Pre-productivo


Los procesos basados en pipelines CI/CD serán gestionados por grupos especializados en *DevSecOps* y *DataSecOps*, lo que facilitará la automatización de los pasos necesarios para el procesamiento y transformación de grandes volúmenes de datos.

Nota: En el repositorio Institucional está documentado la forma de implementar los componentes de software con licenciamiento tipo *Open Source*¹.

En la Figura 4, se muestra el modelo para el proceso de producción de información, en el que se describen las actividades necesarias para generar productos y servicios de información estadística y geográfica del Instituto.

¹ Referencia: <https://git.INEGI.org.mx/laboratorio-de-ciencia-de-datos/lciddatalake.git>

Figura 4. Diagrama para un lago y almacén de datos en el entorno del MPEG.



Fuente: Elaboración LCID-DGI

3.1.3. Gobernanza de Datos Robusta y Adaptable:

- Democratizar el uso del LDI para que cada área administre, procese y explote directamente su información requiere reglas claras de gobierno en estandarización, acceso, uso, documentación y cumplimiento normativo.
- La Gestión de Datos Maestros (MDM) es crucial para reducir inconsistencias y establecer un lenguaje común para objetos clave.
- La implementación de un catálogo de datos que gestione metadatos de datos estructurados y no estructurados es vital para facilitar la búsqueda, descubrimiento y comprensión de datos, asegurando la gobernanza y conformidad con políticas de datos.

3.1.4. Desarrollo de Capital Humano y Habilitación de Nuevos Perfiles:

- Es imperativo habilitar en las UA productoras de información los nuevos perfiles y roles necesarios para que formen parte de este ecosistema de datos. La complejidad de la infraestructura de datos moderna requiere personal capacitado y con experiencia en enfoques de gestión de datos y tecnologías de flujo de datos emergentes.
- Se requiere conformar un equipo técnico en la DGI para administrar la plataforma de software bajo un marco de gobernanza de TI.
- La inversión en talento local con habilidades en machine learning, ciencia de datos e ingeniería de datos es esencial. Los programas de educación y capacitación deben dotar de estas habilidades técnicas prácticas. Además, se debe considerar el impacto de la IA y la automatización en la fuerza laboral y definir planes de reentrenamiento laboral.

3.1.5. Optimización y Automatización Continua:

- La automatización de tareas de procesamiento de datos es crítica para mantener la calidad y precisión de los datos. Esto incluye normalización, deduplicación y limpieza de archivos.
- La optimización del almacenamiento y cómputo con gestión por niveles (datos de acceso frecuente en almacenamiento de alto rendimiento y menos usados en almacenamiento más económico) y el autoescalado son cruciales para controlar los costos y evitar el gasto excesivo en recursos computacionales. El uso de job bookmarks en procesos ETL también puede reducir costos al evitar el reprocesamiento de datos.
- Las soluciones con IA pueden ayudar a perfilar, limpiar y adjuntar nuevos datos a las estructuras existentes, evitando que los lagos de datos se conviertan en "data swamps" y manteniéndolos organizados para una rápida recuperación y análisis.

3.1.6. Gestión del Cambio y Fomento de la Adopción:

- La transición hacia el LDI podría generar dificultades operativas o de integración, y retrasos en la adopción si no se gestionan adecuadamente las expectativas y necesidades de los usuarios. La resistencia al cambio por parte de los usuarios acostumbrados a sus sistemas actuales es un riesgo real.
- Por ello, es fundamental incorporar a un equipo de usuarios durante la ejecución del plan de acción. La inversión en capacitación, comunicación e iniciativas culturales es vital para lograr una mayor adopción por parte de los usuarios y asegurar el éxito del proyecto. Fomentar una cultura donde todos los participantes comprendan su rol en la gobernanza es crucial para crear un entorno de responsabilidad colectiva.

3.2. FASES DE IMPLEMENTACIÓN

Para lograr una implementación exitosa del Lago de Datos Institucional, es fundamental desarrollar un plan de acción integral que guíe las actividades a lo largo de todas sus fases. Este plan debe basarse en una colaboración efectiva entre equipos multidisciplinarios, una planificación cuidadosa, y desde luego, una ejecución ordenada.

Este enfoque colaborativo no solo facilita la integración de diferentes áreas de conocimiento al proyecto, sino que también permite que los miembros de los equipos involucrados, en sus respectivos roles, conozcan de primera mano las implicaciones técnicas y estructurales del proyecto.

La metodología del Marco de Arquitectura de Lagos de Datos (DLAF) define nueve aspectos clave (infraestructura, almacenamiento, flujo, modelado, organización, procesos, seguridad y privacidad y, calidad de datos, así como la gestión de metadatos) y sus interdependencias. Estas perspectivas se integran y abordan a lo largo de las siguientes fases de implementación, las cuales se estructuran para garantizar un desarrollo progresivo y controlado:

Figura 5. Fases del plan de acción para la implementación del Lago de Datos Institucional.



Fuente: Elaboración LCID y DGI.

Fase 1. Preparación y planificación.

Se establecen los cimientos del proyecto, asegurando el alineamiento estratégico, la designación de equipos y la identificación de las necesidades iniciales.

Objetivos:

- Identificar los problemas o necesidades institucionales que la iniciativa debe abordar.
- Determinar qué datos se incluirán en el LDI (datos crudos, estructurados, semiestructurados) y los casos de uso específicos que se abordarán inicialmente (piloto), así como las áreas que se verán beneficiadas.
- Designar un equipo interdisciplinario que incluya personas expertas en datos, arquitectos de sistemas, especialistas en seguridad y personas usuarias clave, entre otros.
- Asegurar el apoyo ejecutivo y los recursos necesarios.

Fase 2. Diseño arquitectónico.

Se diseña la arquitectura del Lago de Datos Institucional, considerando los requisitos de almacenamiento, procesamiento y seguridad, con pleno apego a las disposiciones normativas. Esto puede incluir la implementación por capas: de almacenamiento, de procesamiento y de servicios de consulta o consumo. Además, se definen estructuras de datos adecuados que faciliten las tareas destinadas a transformar, limpiar y organizar los datos almacenados, para que sean de utilidad para el análisis, y que apoyen además la gestión de cambios incrementales en los conjuntos de datos para mantener un control de versiones.

En materia de evaluación de tecnologías y plataformas, se seleccionan las tecnologías adecuadas para su implementación. Esto puede incluir evaluar plataformas de almacenamiento en la nube, sistemas de procesamiento de datos en tiempo real y por lotes, y herramientas de gestión de datos. Se deberá verificar que las tecnologías seleccionadas sean compatibles con las herramientas y sistemas existentes en el Instituto, que faciliten la interoperabilidad sin afectar a su plataforma tecnológica base.

La gobernanza es crucial, estableciendo políticas y procedimientos para la gestión de datos en el Lago de Datos Institucional, incluyendo la calidad de los datos, el acceso y los controles de seguridad, y el cumplimiento normativo.

Respecto de la seguridad, se identifican y fortalecen las medidas de seguridad cibernética y protección de datos, para garantizar la integridad y la confidencialidad de la información almacenada en el Lago de Datos Institucional.

Objetivos:

- Diseñar la arquitectura del Lago de Datos Institucional, considerando los requisitos de almacenamiento, procesamiento y seguridad, con pleno apego a las disposiciones normativas. Esto puede incluir la implementación por capas: de almacenamiento, de procesamiento y de servicios de consulta o consumo.
- Definir estructuras de datos adecuadas que faciliten las tareas destinadas a transformar, limpiar y organizar los datos almacenados, y que apoyen la gestión de cambios incrementales en los conjuntos de datos para mantener un control de versiones.
- Evaluar y seleccionar las tecnologías adecuadas para implementarlo (plataformas de almacenamiento en la nube, sistemas de procesamiento de datos en tiempo real y por lotes, y herramientas de gestión de datos). Verificar la compatibilidad con los sistemas existentes del Instituto.
- Establecer políticas y procedimientos para la gestión de datos, incluyendo calidad, acceso, controles de seguridad y cumplimiento normativo.
- Identificar y fortalecer las medidas de seguridad cibernética y protección de datos, para garantizar la integridad y la confidencialidad de la información.

Fase 3. Implementación y despliegue.

En esta fase se pone en marcha la infraestructura y las funcionalidades del LDI, comenzando con un piloto y escalando gradualmente.

Objetivos:

- Realizar una implementación piloto para validar la arquitectura y los flujos de datos, permitiendo ajustes y optimizaciones.
- Hacer un despliegue gradual, implementando en fases o iteraciones, comenzando con conjuntos de datos o casos de uso prioritarios.
- Configurar la infraestructura necesaria (almacenamiento, computación, redes).
- Instalar y configurar las herramientas y tecnologías de software seleccionadas.
- Desarrollar e implementar los flujos de datos para la ingesta automática y las transformaciones requeridas.
- Realizar pruebas exhaustivas (unitarias, de integración, de carga y rendimiento) para asegurar la funcionalidad y seguridad.

Fase 4. Capacitación y adopción.

Se deberá asegurar que los usuarios y administradores del LDI posean las habilidades y conocimientos necesarios para su uso efectivo y que la plataforma sea adoptada por toda la organización.

Objetivos:

- Proporcionar formación adecuada al personal según su rol sobre cómo administrar, utilizar y gestionar el LDI. Los programas de educación y capacitación deben dotar a los estudiantes de habilidades en machine learning, ciencia de datos, ingeniería de datos y habilidades técnicas prácticas.
- Promover la utilización del LDI dentro del Instituto mediante demostraciones de casos de uso implementados y fomentar la comunicación efectiva sobre los beneficios.
- Implementar estrategias de gestión del cambio para facilitar la adopción y asegurar el uso efectivo, abordando la resistencia potencial al cambio. La inversión en capacitación, comunicación e iniciativas culturales es vital para lograr una mayor adopción y el éxito del proyecto.

Fase 5. Monitoreo y optimización continua.

Mantener el rendimiento óptimo del LDI, identificar áreas de mejora y asegurar la conformidad continua con las normativas.

Objetivos:

- Establecer métricas de rendimiento y monitorear continuamente el LDI (rendimiento, disponibilidad, utilización) para identificar áreas de mejora.
- Realizar ajustes y mejoras continuas en la arquitectura y los procesos para optimizar el rendimiento y la escalabilidad.
- Identificar y abordar cuellos de botella, mejorar flujos de datos y ajustar la configuración de infraestructura.
- Realizar revisiones periódicas del diseño y arquitectura para asegurar su adecuación a los requisitos cambiantes y tecnologías emergentes.

Fase 6. Evaluación y Aprendizaje.

Se analizan los resultados alcanzados, identificar lecciones y documentar las mejores prácticas para futuros proyectos.

Objetivos:

- Realizar una evaluación exhaustiva del proyecto para analizar los resultados alcanzados frente a los objetivos establecidos.
- Recopilar retroalimentación de los usuarios finales y partes interesadas para identificar áreas de mejora y oportunidades adicionales.
- Identificar lecciones aprendidas y áreas de mejora para futuras implementaciones o expansiones.
- Documentar el diseño, la arquitectura, los procesos y las lecciones aprendidas.
- Crear un repositorio de conocimientos accesible para el equipo de proyecto y otros equipos.

Fase 7. Mantenimiento y soporte continuo.

Garantizar la continuidad operativa del LDI a largo plazo, su evolución y adaptabilidad a los cambios tecnológicos y comerciales.

Objetivos:

- Establecer procedimientos para la gestión de incidentes y solicitudes de soporte.
- Mantener actualizaciones regulares de software y parches de seguridad.
- Monitorear las tendencias tecnológicas y las necesidades del Instituto para identificar oportunidades de mejora y expansión.
- Planificar actualizaciones y mejoras iterativas para mantener la relevancia y la eficacia del LDI a largo plazo.

3.3. PLAN DE ACCIÓN

Con base en el modelo por fases propuesto, se ha diseñado el siguiente plan de actividades que conduzca las tareas de manera ordenada, proporcionando la estructura necesaria para que el equipo logre el objetivo de manera eficiente. La automatización de tareas de procesamiento de datos, incluyendo normalización, de-duplicación y limpieza, es crítica para mantener la calidad y precisión de los datos. El monitoreo continuo del uso de datos y el seguimiento del linaje de datos son fundamentales para comprender el flujo y la utilización de los datos, apoyando la resolución de problemas y el cumplimiento normativo.

Tareas	Actividades	Responsables	Entregables	Fecha propuesta
Fase 1: Preparación y Planificación Objetivos: -Establecer un equipo de proyecto y asignar roles y responsabilidades. -Definir los objetivos y beneficios esperados del Lago de Datos Institucional. -Identificar y asegurar el apoyo ejecutivo y los recursos necesarios.				
1.1 Formación del Equipo	- Designar una persona líder del proyecto. - Seleccionar miembros con perfiles clave (ej. Ingenieros de datos, Científicos de datos, Analistas de datos, Arquitectos de datos, Administradores de plataforma/Ingenieros de plataforma)	<i>Patrocinador(a)</i>	- Nombramiento del equipo de trabajo con definición de roles y responsabilidades.	4to trimestre 2025
1.2 Definición de objetivos	- Convocar a talleres y reuniones con partes interesadas (UA) para identificar y entender las necesidades y los requisitos de datos. - Documentar los alcances, objetivos específicos y beneficios del LDI.	<i>Patrocinador(a)</i> <i>Persona líder del proyecto</i> <i>Gestor(a) de gobernanza de datos</i>	- Minutas de acuerdos - Especificación de alcances y objetivos establecidos en coordinación con las partes interesadas (UA)	1er bimestre 2026
1.3 Plan de presentación del proyecto	- Desarrollar plan de comunicación e integrar actividades preparatorias de gestión del cambio para la adopción efectiva. - La resistencia al cambio es un desafío real, por lo que la inversión en capacitación, comunicación e iniciativas culturales es crucial.	<i>Persona líder del proyecto</i> <i>Gestor(a) de Gobernanza de Datos</i>	- Presentación ejecutiva del proyecto. - Plan de gestión del cambio (incluyendo impacto en procesos, personas, tecnología y áreas de resistencia).	1er bimestre 2026
Fase 2: Diseño y Arquitectura Objetivos:				

Tareas	Actividades	Responsables	Entregables	Fecha propuesta
- Definir la arquitectura técnica y el modelo de datos del Lago de Datos Institucional - Seleccionar las tecnologías y herramientas adecuadas para la implementación. - Establecer políticas de gobernanza y seguridad de los datos				
2.1 Diseño de la Arquitectura	- Seleccionar y diseñar una arquitectura adecuada para el Lago de Datos Institucional. - Diseñar la estructura de la capa de datos (almacenamiento) y las capas de seguridad relacionada con el acceso para facilitar la ingestión, transformación y acceso a los datos. Nota: tomando en cuenta la experiencia del LCID y la arquitectura inicial propuesta.	<i>Arquitecto(a) de datos</i>	- Diagrama de arquitectura. - Diseño de Componentes (ingesta, almacenamiento, procesamiento, consulta, análisis, plataformas de software).	Segundo bimestre 2026
2.2 Evaluación de la Infraestructura	- Realizar una evaluación de la infraestructura existente para determinar si es adecuada y suficiente para soportar un Lago de Datos Institucional. - Identificar posibles necesidades de actualización o expansión de la infraestructura de TI, como almacenamiento escalable y capacidad de procesamiento.	<i>Arquitecto(a) de datos</i> <i>Administrador(a) de infraestructura</i> <i>Administrador(a) de plataformas</i>	- Informe de Evaluación de Infraestructura Actual - Plan de Actualización de Infraestructura y plataforma de software. - Evaluación de Costos. Nota: en caso de haber necesidades de actualización o expansión.	Segundo bimestre 2026
2.3 Modelado de Datos	- Definir el esquema de datos para el Lago de Datos Institucional, incluyendo la integración con fuentes de datos existentes y la preparación de datos para el análisis. - Diseñar flujos para la ingestión automatizada de datos desde diversas fuentes hacia el Lago de Datos Institucional (la Gestión de Datos Maestros (MDM por sus siglas en inglés), es crucial para reducir inconsistencias y establecer un lenguaje común. Nota: tomando en cuenta la experiencia relacionada con los casos de uso (prototipos) desarrollados por las UA en el LCID que se describen en el ANEXO 4.	<i>Arquitecto(a) de datos</i> <i>Ingeniero(a) de datos</i> <i>Analista de datos</i>	- Documento de requisitos de datos. - Diagrama de flujo de datos. - Especificaciones de flujo de datos.	Segundo bimestre 2026

Tareas	Actividades	Responsables	Entregables	Fecha propuesta
2.4 Gobernanza y Seguridad	- Establecer políticas y procedimientos de gobernanza de datos para asegurar la calidad, integridad, conservación y acceso adecuado a los datos. - Diseñar controles de seguridad robustos, como cifrado de datos, autenticación y autorización basada en roles, y auditorías de seguridad periódicas (seguridad “by design” es fundamental).	<i>Gestor(a) de Gobernanza de Datos</i> <i>Especialista en Seguridad de la Información</i>	- Plan de Gestión de Acceso y Control. - Evaluación e instauración de mecanismos de seguridad. - Plan de Continuidad del Negocio y Recuperación ante Desastres. - Plan de Gobernanza de Datos (incluyendo reglas y procedimientos para calidad, catalogación y metadatos).	Segundo bimestre 2026
Fase 3: Implementación y Despliegue Objetivos: - Implementar la infraestructura y configurar el Lago de Datos Institucional Nota: se considera en dos fases. La primera, con recursos para el despliegue de un piloto que pueda ser realizado con recursos que se tengan disponibles considerando los recursos de la arquitectura inicial para un ambiente pre-productivo. Y la segunda, para la implementación de necesidades adicionales que se hayan detectado para el despliegue a nivel institucional de un ambiente productivo, que podrían implicar la autorización de recursos presupuestales. - Desarrollar y desplegar flujos para la ingestión y procesamiento de datos. - Realizar pruebas exhaustivas para validar la funcionalidad y seguridad del Lago de Datos Institucional				
3.1 Configuración de la Infraestructura	- Implementar y configurar la infraestructura necesaria para el Lago de Datos Institucional, incluyendo almacenamiento, computación y servicios de red.	<i>Administrador(a) de infraestructura</i>	- Plan de Implementación de Infraestructura y plataformas de software	1ra fase. Segundo cuatrimestre 2026
3.2 Configuración de la plataforma de software	- Instalar y configurar las herramientas y tecnologías seleccionadas para el Lago de Datos Institucional	<i>Administrador(a) de plataforma de software</i>		2da fase Primer semestre 2027
3.3 Desarrollo de flujos de Datos	- Desarrollar flujos de datos para la ingestión automática de datos desde diversas fuentes hacia el Lago de Datos Institucional.	<i>Ingeniero(a) de datos</i> <i>Analista de datos</i>		Tercer cuatrimestre 2026

Tareas	Actividades	Responsables	Entregables	Fecha propuesta
	- Implementar transformaciones de datos según los requisitos de datos y de análisis.			
3.4 Pruebas y Validación	- Realizar pruebas unitarias y de integración para cada componente del Lago de Datos Institucional. - Ejecutar pruebas de carga y rendimiento para asegurar que el sistema pueda manejar volúmenes esperados de datos y consultas.	<i>Administrador(a) de plataforma de software</i> <i>Ingeniero(a) de datos</i> <i>Especialista en Seguridad de la Información</i> <i>Equipo de personas usuarias</i>	- Estrategia de pruebas - Casos de pruebas	Tercer cuatrimestre 2026

Fase 4: Capacitación y Adopción

Objetivos:

- Capacitar a las y los usuarios finales y administradores en el uso y mantenimiento del Lago de Datos Institucional
- Promover la adopción del Lago de Datos Institucional.

Nota: en esta fase seguramente habrá que repetir actividades tales como las descritas en los objetivos 2.3, 3.3 y 3.4, ya que al integrar nuevas personas s usuarias significa diseñar nuevos flujos de datos, implementarlos y probarlos. Por eso, se establece en el modelo de acción que el despliegue es gradual, implementando en fases o iteraciones.

4.1 Formación y capacitación	- Desarrollar y ofrecer programas de formación sobre el uso del Lago de Datos Institucional, herramientas de análisis y mejores prácticas de gestión de datos. - Capacitar a personas administradoras sobre la monitorización, gestión y mantenimiento continuo del Lago de Datos Institucional -	<i>Equipo de Soporte y Capacitación</i>	- Materiales de capacitación - Plan de capacitación.	Último bimestre 2026
4.2 Comunicación y gestión del cambio.	- Realizar sesiones informativas y talleres para comunicar a las y los beneficios del Lago de Datos Institucional a personas usuarias y/o candidatas potenciales. - Implementar estrategias de gestión del cambio para facilitar la adopción y asegurar el uso efectivo del Lago de Datos Institucional -	<i>Equipo de Soporte y Capacitación</i>		Último bimestre 2026

Fase 5: Monitoreo y Optimización Continua

Objetivos:

Tareas	Actividades	Responsables	Entregables	Fecha propuesta
- Monitorear el rendimiento y la utilización del Lago de Datos Institucional - Identificar oportunidades de mejora y optimización. - Mantener la seguridad y la conformidad con las normativas.				
5.1 Monitoreo y métricas	- Implementar herramientas de monitoreo para supervisar rendimiento, disponibilidad y utilización del Lago de Datos Institucional. - Definir métricas clave para evaluar la efectividad del Lago de Datos Institucional y la satisfacción de las personas usuarias.	<i>Administrador(a) de plataforma de software</i> <i>Gestor(a) de Gobernanza de Datos</i>	- Plan de monitoreo y configuración de alertas.	Último bimestre 2026– Primer Semestre 2027 Permanente (una vez que se establezcan)
5.2 Optimización y Escalabilidad	- Realizar ajustes y mejoras continuas en la arquitectura y los procesos del Lago de Datos Institucional para optimizar rendimiento y escalabilidad. - Identificar y abordar cuellos de botella, mejorar los flujos de datos y ajustar la configuración de infraestructura, según sea necesario.	<i>Administrador(a) de infraestructura</i> <i>Administrador(a) de plataforma de software</i> <i>Arquitecto(a) de datos</i> <i>Ingeniero(a) de datos</i>		Permanente
5.3 Revisión y actualización	- Realizar revisiones periódicas del diseño y la arquitectura del Lago de Datos Institucional para asegurar que sigan siendo adecuados para los requisitos cambiantes del negocio y las tecnologías emergentes.	<i>Administrador(a) de infraestructura</i> <i>Administrador(a) de plataforma de software</i> <i>Arquitecto(a) de datos</i>		Permanente
Fase 6: Evaluación de Resultados y Documentación Objetivos: - Evaluar el impacto del Lago de Datos Institucional en los objetivos comerciales y operativos. - Documentar lecciones aprendidas y mejores prácticas para futuros proyectos.				
6.1 Análisis de impacto	- Evaluar el éxito del proyecto para lograr objetivos, mejorar eficiencia operativa, toma de decisiones informadas y otros beneficios esperados.	<i>Persona líder del proyecto</i> <i>Gestor(a) de Gobernanza de Datos</i>	- Informe de Evaluación de Resultados - Lecciones aprendidas	Último bimestre 2026 –

Tareas	Actividades	Responsables	Entregables	Fecha propuesta
	- Recopilar retroalimentación de las y los usuarios finales y partes interesadas para identificar áreas de mejora y oportunidades adicionales.			Primer Semestre 2027
6.2 Documentación y gestión del conocimiento	- Documentar el diseño, arquitectura, procesos y lecciones aprendidas durante la implementación del Lago de Datos Institucional - Crear un repositorio de conocimientos accesible para el equipo de proyecto y otros equipos a través de la plataforma del Grupo de Coordinación en Tecnologías de Información y Comunicaciones (GCTIC.)	<i>Persona líder del proyecto</i> <i>Gestor(a) de Gobernanza de Datos</i>		
Fase 7: Mantenimiento y Soporte Continuo Objetivos - Proporcionar soporte continuo y mantenimiento del Lago de Datos Institucional - Asegurar la evolución y la adaptabilidad del Lago de Datos Institucional frente a cambios tecnológicos y comerciales.				
7.1 Soporte y mantenimiento	- Establecer procedimientos para la gestión de incidentes y solicitudes de soporte. - Mantener actualizaciones regulares de software y parches de seguridad para proteger la integridad y la seguridad de los datos.	<i>Especialista en Seguridad de la Información</i> <i>Administrador(a) de infraestructura</i> <i>Administrador(a) de plataformas</i>	- Guía de operación - Procedimientos de mantenimiento - Ficha técnica de servicios informáticos	Permanente
7.2 Evolución y mejora Continua	- Monitorear las tendencias tecnológicas y las necesidades del Instituto para identificar oportunidades de mejora y expansión del Lago de Datos Institucional - Planificar actualizaciones y mejoras iterativas para mantener la relevancia y la eficacia del Lago de Datos Institucional a largo plazo.	<i>Persona líder de Proyecto</i> <i>Administrador(a) de plataformas</i> <i>Arquitecto(a) de datos</i>		Permanente

3.4. ACTORES CLAVE

Los perfiles clave que deben participar en el proyecto son los siguientes:

Perfil	Responsabilidades	Habilidades	UA
<i>Patrocinador(a)</i>	Proporcionar dirección estratégica, asegurar recursos y apoyar la adopción del proyecto en toda la organización.	Visión estratégica, capacidad para tomar decisiones informadas y habilidades de comunicación efectiva.	CGED - DGI
<i>Líder de Proyecto</i>	Supervisar todo el proyecto desde la planificación hasta la implementación y el mantenimiento.	Experiencia en gestión de proyectos, capacidad para manejar equipos multidisciplinarios y asegurar la entrega dentro del presupuesto y plazos establecidos.	CGED
<i>Arquitecto(a) de Datos</i>	Diseñar la arquitectura técnica del Lago de Datos Institucional, incluyendo el modelado de datos y la integración de sistemas.	Conocimiento de tecnologías de almacenamiento de datos, experiencia en diseño de bases de datos y habilidades en integración de sistemas.	DGI DGAIAI (personal de LCID)
<i>Ingeniero(a) de Datos</i>	Desarrollar flujos de datos para la ingestión, transformación y carga de datos.	Experiencia en programación (por ejemplo, <i>Python</i> , <i>SQL</i>), conocimiento de herramientas de ETL (Extract, Transform, Load) y experiencia en gestión de grandes volúmenes de datos	DGAIAI, DGI y UGMA colaboran según la fuente y tipo de datos.
<i>Analista de Datos</i>	Utilizar herramientas de análisis para extraer información útil de los datos almacenados.	Experiencia en análisis de datos, y estar familiarizado con herramientas como <i>Tableau</i> , <i>Power BI</i> , o lenguajes como <i>R</i> y/o <i>Python</i> para análisis estadístico.	DGCSPIRI DGI y UGMA (según el destino y tipo de la información).
<i>Especialista en Seguridad de la Información</i>	Garantizar la seguridad y protección de los datos almacenados en el Lago de Datos Institucional.	Conocimientos sólidos en ciberseguridad, experiencia en implementación de controles de acceso, cifrado de datos, y cumplimiento de normativas de privacidad.	DGI (seguridad informática) DGAIAI (seguridad de la información)
<i>Administrador(a) de infraestructura</i>	Proveer, mantener y administrar la infraestructura de cómputo	Experiencia en administración de infraestructura de cómputo y capacidad para solucionar problemas técnicos.	DGI
<i>Administrador(a) de plataformas</i>	Mantener y administrar las plataformas de Software.	Experiencia en administración de plataformas de software y capacidad para solucionar problemas técnicos.	DGI
<i>Gestor(a) de Gobernanza de Datos</i>	Establecer políticas y procedimientos para asegurar la calidad y el uso ético de los datos dentro del entorno del Lago de Datos Institucional	Conocimientos en gobernanza de datos, experiencia en definición de políticas de datos,	DGAIAI

Perfil	Responsabilidades	Habilidades	UA
		gestión de metadatos y diseño de indicadores clave de medición.	
<i>Equipo de personas usuarias</i>	Proveer retroalimentación sobre los requisitos de datos y validar los casos de uso que se definan.	Conocimiento profundo del negocio y habilidades para comunicar necesidades y expectativas a los desarrolladores y analistas de datos.	UA productoras
<i>Equipo de Soporte y Capacitación</i>	Proporcionar soporte técnico continuo y capacitar a las personas usuarias, en el uso de los servicios informáticos para operar en el entorno de datos del Lago de Datos institucional	Experiencia en soporte técnico, capacidad para comunicar de manera efectiva conceptos técnicos a personas usuarias.	DGIAI DGI

3.5. ENTREGABLES

Los entregables del proyecto y la descripción de sus contenidos, de carácter no limitativo, son los siguientes:

Fase	Entregable y descripción/contenido	Responsable
Fase 1: Preparación y Planificación	1. Minutas de acuerdos.	<i>Persona líder del proyecto</i>
	2. Especificación de alcances y objetivos establecidos en coordinación con las partes interesadas (UA).	<i>Persona líder de proyecto</i> <i>Gestor(a) de gobernanza de datos</i>
	3. Nombramiento del equipo de trabajo con definición de roles y responsabilidades.	<i>Patrocinador(a)</i>
	4. Presentación ejecutiva del proyecto.	<i>Persona líder de proyecto</i> <i>Gestor(a) de gobernanza de datos</i>
	5. Plan de gestión del cambio: a. Impacto en procesos, personas, tecnología, y posibles áreas de resistencia.	<i>Persona líder de proyecto</i> <i>Gestor(a) de gobernanza de datos</i>
Fase 2: Diseño y Arquitectura	Informe de Evaluación de Infraestructura Actual: – Informe que evalúa si la infraestructura actual puede manejar la carga de trabajo y los requisitos de rendimiento del Lago de Datos Institucional. Nota: esto incluye la valoración de los recursos destinados actualmente para el LCID.	<i>Administrador(a) de infraestructura</i>
	Plan de Actualización de Infraestructura y plataforma de software: – Documento que detalla las actualizaciones y mejoras necesarias para soportar el Lago de Datos Institucional. – Requisitos de <i>hardware</i> y <i>software</i> adicionales y/o actualizaciones necesarias para soportar la tecnología asociada al Lago de Datos Institucional.	<i>Administrador(a) de infraestructura</i> <i>Administrador(a) de plataformas</i>

Fase	Entregable y descripción/contenido	Responsable
	– Compatibilidad con tecnología asociada al Lago de Datos Institucional.	
	Evaluación de Costos: – Plan de proveedores. – Investigación de mercado.	<i>Administrador(a) de infraestructura</i> <i>Administrador(a) de plataformas</i>
	Diagrama de arquitectura: – Representación visual de la arquitectura del Lago de Datos Institucional, que muestra los componentes principales, sus interacciones y cómo se integran con otros sistemas.	<i>Arquitecto(a) de Datos</i>
	Diseño de Componentes de la arquitectura: – Componentes: ingesta de datos, almacenamiento, procesamiento y consulta, y análisis. – Plataforma de <i>software</i> para cada uno de los componentes.	<i>Arquitecto(a) de Datos</i> <i>Administrador(a) de plataformas</i>
	Requerimiento de datos: – Fuentes de datos, frecuencia de actualización, formatos de datos y volumen esperado. – Reglas de transformación y reglas de calidad de datos necesarias. – Características de los entregables, formatos y reglas a cumplir.	<i>Equipo de Personas Usuarias</i> <i>Ingeniero(a) de datos</i>
	Diagrama de procesos y de los flujos de datos: – Documento que describe cómo se construirán y configurarán los flujos de datos, incluyendo detalles sobre la ingesta, procesamiento, y almacenamiento de datos. Lo anterior con base en el Modelo de Procesos de Producción Estadística y Geográfica (MPEG) que establezca la DGIAI.	<i>Ingeniero(a) de datos</i>
	Plan de Gestión de Acceso y Control.	<i>Administrador(a) de plataformas</i>
	Evaluación de Seguridad.	<i>Especialista en Seguridad de la Información</i>
	Plan de Continuidad del Negocio y Recuperación ante Desastres.	<i>Especialista en Seguridad de la Información</i>
Fase 3: Implementación y Despliegue	Plan de Gobernanza de Datos: – Reglas y procedimientos para la gestión de datos, incluyendo calidad, catalogación, y mantenimiento de metadatos.	<i>Gestor(a) de Gobernanza de Datos</i>
	Plan de Implementación de Infraestructura: – Documento que detalla las actualizaciones y mejoras necesarias para soportar el Lago de Datos – Requisitos de hardware y software adicionales, sus costos y cronograma propuesto para la implementación de las mejoras.	<i>Administrador(a) de infraestructura</i> <i>Administrador(a) de plataformas</i>
	Estrategia de Pruebas:	<i>Ingeniero(a) de datos</i>

Fase	Entregable y descripción/contenido	Responsable
	Documento que describe los enfoques para probar los flujos de datos antes de su implementación, incluyendo pruebas de integración, de rendimiento y de validación de datos.	<i>Equipo de Personas Usuarías</i>
	Casos de Prueba: Casos específicos que se usarán para verificar que los flujos de datos funcionen correctamente y cumplan con los requisitos establecidos.	<i>Ingeniero(a) de datos</i> <i>Equipo de Personas Usuarías</i>
Fase 4: Capacitación y Adopción	Materiales de capacitación: - Manuales de uso, tutoriales, guías rápidas, y módulos de formación en línea. Plan de capacitación: - Cronograma de capacitación, formatos de entrenamiento, y requisitos de formación.	<i>Equipo de Soporte y Capacitación</i>
Fase 5: Monitoreo y Optimización Continua	Plan de Monitoreo: - Documento que detalla cómo se monitorearán los flujos de datos para asegurar que funcionen correctamente, incluyendo métricas clave y herramientas de monitoreo. Configuración de Alertas: - Especificaciones para configurar alertas que notifiquen a los administradores sobre problemas o anomalías en la ejecución de los pipelines.	<i>Administrador(a) de infraestructura</i> <i>Administrador(a) de plataforma de software</i> <i>Arquitecto(a) de datos</i> <i>Ingeniero(a) de datos</i>
Fase 6: Evaluación de Resultados y Documentación	Informe de Evaluación de Resultados: - Un análisis de hasta qué punto se han cumplido los objetivos y requisitos del proyecto, incluyendo cualquier desviación de los planes iniciales. Lecciones aprendidas: - Reflexiones sobre lo que funcionó bien y lo que podría mejorarse en futuros proyectos. Incluye buenas prácticas y recomendaciones basadas en la experiencia del proyecto.	<i>Persona líder del proyecto</i> <i>Gestor(a) de Gobernanza de Datos</i>
Fase 7: Mantenimiento y Soporte Continuo	Guía de Operación: Documento que explica cómo operar y gestionar los flujos de datos una vez que estén en funcionamiento, incluyendo tareas diarias y mantenimiento. Procedimientos de Mantenimiento:	<i>Administrador(a) de plataformas de software</i> <i>Arquitecto(a) de datos</i> <i>Ingeniero(a) de datos</i>

Fase	Entregable y descripción/contenido	Responsable
	– Instrucciones para realizar mantenimiento regular en los flujos de datos, como actualizaciones, ajustes y optimización de rendimiento. Ficha técnica de servicios informáticos.	

3.6. CONSIDERACIONES ADICIONALES

Colaboración y comunicación:

Fomentar la colaboración entre todos los equipos involucrados y mantener una comunicación clara y abierta durante todas las etapas del proyecto. Es importante para ello contar con el apoyo de la alta dirección para garantizar el involucramiento y compromiso de todas las partes.

Flexibilidad y adaptabilidad:

Habilitar el espacio para posibles ajustes al plan, según surjan nuevos requisitos o desafíos durante la implementación del Lago de Datos Institucional, ya que hay factores externos como la autorización de presupuesto o factores internos como prioridades en las cargas de trabajo de las partes involucradas que pueden afectar el tiempo o los alcances de los objetivos establecidos.

Cultura de Datos y Responsabilidad Colectiva:

Es crucial fomentar una cultura donde todos los participantes comprendan su rol en la gobernanza, creando un entorno de responsabilidad colectiva. Esto implica invertir en capacitación, comunicación e iniciativas culturales para lograr una mayor adopción por parte de los usuarios y asegurar el éxito del proyecto.

La modernización de las políticas y prácticas de gestión de recursos humanos es esencial para asegurar que las habilidades necesarias estén disponibles en la administración pública.

Optimización de Costos y Recursos:

La habilidad para gestionar y optimizar los costos en un lago de datos es crucial, utilizando prácticas como el dimensionamiento adecuado de instancias, el uso de instancias Spot/Reservadas, el autoescalado y la elección de herramientas adecuadas.

El entrenamiento y desarrollo de la IA aumentan el consumo de energía, lo que requiere algoritmos y una infraestructura más eficiente energéticamente, un factor a considerar en la valoración de arquitecturas.

Enfoque Centrado en el Usuario (Human-Centric):

Adoptar un enfoque centrado en el ser humano que ponga las necesidades y valores de las personas y comunidades en el centro de la gobernanza y el despliegue de la IA.

Interoperabilidad como Habilitador Clave:

Reconocer la interoperabilidad no solo como un objetivo técnico, sino como un elemento transversal que facilita el intercambio de datos y la colaboración entre diferentes sistemas y entidades gubernamentales. Esto es fundamental para la modernización de sistemas heredados y la captura de información dispersa en silos.

4. SEGURIDAD Y PRIVACIDAD EN LAGOS DE DATOS

En la era digital actual, en la que el volumen de datos sigue una tendencia de crecimiento exponencial, la seguridad y la privacidad de la información en los lagos de datos se han convertido en pilares fundamentales para las organizaciones que buscan impulsar el crecimiento empresarial y la ventaja competitiva. La "Iniciativa de Estrategia Digital" del Instituto reconoce esta necesidad, al proponer una plataforma que no solo optimice la gestión y el análisis de datos, sino que también asegure **condiciones óptimas de gobernanza, acceso y seguridad de la información**.

El establecimiento de medidas de seguridad robustas y la implementación de políticas de privacidad son esenciales para proteger los activos de información de una organización, mantener la confianza con los usuarios y cumplir con los requisitos legales y regulatorios. Sin estas medidas, un lago de datos corre el riesgo de convertirse en un pantano de datos, en el que los datos son inutilizables o vulnerables a amenazas.

4.1. Consideraciones de Seguridad en Entornos de Datos Centralizados

La centralización de los activos de datos de una organización en un lago de datos, aunque ofrece grandes beneficios en términos de análisis y gestión, también incrementa las consideraciones de seguridad y cumplimiento.

La falta de gobernanza y medidas de seguridad adecuadas puede llevar a la violación de datos, a su uso indebido o al incumplimiento normativo. Sin una clara propiedad de los datos o un control de acceso adecuado, las organizaciones pueden encontrarse en un estado de caos de datos.

4.2. Marcos de Seguridad Robustos

Para mitigar estos desafíos, las organizaciones deben adoptar un enfoque de seguridad por capas. Un marco de seguridad robusto es fundamental para el lago de datos. La integración de la seguridad en el diseño inicial de la arquitectura es clave para el éxito.

Las estrategias clave incluyen:

4.2.1. Controles de Acceso Granulares:

- Es fundamental implementar controles de acceso basados en roles (RBAC) para garantizar que los individuos accedan únicamente a los datos necesarios para sus funciones. Esto minimiza la posible exposición de datos.
- La implementación efectiva de RBAC requiere una gestión y ajuste continuos a medida que los roles dentro de una organización evolucionan o se añaden nuevos elementos de datos al lago de datos. Auditar regularmente los derechos de acceso es crucial para mantener un entorno seguro y conforme, mitigando el riesgo de brechas de datos debido a permisos de acceso excesivos.
- Se debe dar acceso de solo lectura por defecto, otorgando permisos de escritura solo cuando sea estrictamente necesario.
- Además, se recomienda reemplazar las credenciales convencionales por identidades administradas para eliminar los riesgos de fuga de credenciales y fortalecer la seguridad con políticas de acceso condicional y autenticación multifactor (MFA) para operaciones sensibles.

4.2.2. Estrategias de Cifrado:

- El cifrado de datos es esencial para proteger la privacidad y la integridad de los datos en los lagos de datos. Al cifrar los datos en reposo y en tránsito, las organizaciones pueden asegurar que, incluso si se obtiene acceso no autorizado, la información permanezca protegida.
- Es importante gestionar las claves de cifrado de forma segura, rotarlas frecuentemente y usar módulos de seguridad de hardware dedicados.

4.2.3. Técnicas de Desidentificación:

- La anonimización y la pseudonimización son técnicas que se pueden emplear para proteger la privacidad individual mientras se permite el análisis de datos.

4.2.4. Registro de Auditoría y Monitoreo:

- Las capacidades exhaustivas de registro y monitoreo de auditoría proporcionan una capa de seguridad esencial.
- La implementación de pistas de auditoría permite a las organizaciones rastrear el acceso y las modificaciones de los datos, proporcionando transparencia y responsabilidad. Esto es esencial para mantener la integridad de los datos y asegurar el cumplimiento de las regulaciones de la organización.
- Se debe desplegar monitoreo continuo para supervisar el rendimiento, la disponibilidad y la utilización del lago de datos, y definir métricas clave para evaluar su efectividad y la satisfacción de los usuarios.

4.3. Seguridad "by Design"

La seguridad no es algo que se añada al final de la implementación. En cambio, debe ser un componente fundamental de la estrategia del lago de datos desde las fases iniciales del diseño.

La "Iniciativa de Estrategia Digital" contempla la integración de prácticas basadas en canales de integración y distribución continua (CI/CD), así como en enfoques como DevSecOps y DataSecOps, que permiten integrar prácticas de seguridad en el ciclo de vida de la gestión de datos y el desarrollo de aplicaciones que interactúan con el ecosistema de datos.

4.4. Interoperabilidad y Seguridad de la Información

La seguridad-by-design es un habilitador clave para el aprovechamiento de APIs (Interfaces de Programación de Aplicaciones). Las APIs son fundamentales para que los datos sean accesibles entre sistemas gubernamentales de manera eficiente y controlada. Es crucial que los desarrolladores de API comprendan los riesgos asociados y contribuyan a interacciones seguras entre aplicaciones con el mínimo esfuerzo, y que los profesionales de ciberseguridad monitoreen continuamente estas APIs con visibilidad y controles integrados.

La interoperabilidad es crucial para compartir información de amenazas cibernéticas (CTII) de manera segura, salvaguardando la información personal y clasificada. Esto requiere un enfoque estratégico de cuatro capas:

1. *Capa Legal:* Define los marcos legales y regulaciones para el intercambio de información y datos.
2. *Capa de Políticas y Procedimientos:* Establece las normativas y procesos para el intercambio de CTII.
3. *Capa Semántica y Sintáctica:* Asegura que los sistemas puedan interpretar la información intercambiada de manera significativa y precisa.
4. *Capa Técnica:* Incluye las infraestructuras y aplicaciones que conectan sistemas y servicios, como protocolos de comunicación segura.